Penarikan Kesimpulan dan Pengujian Hipotesis Data Matriks Kualitas Air

April 15, 2022

1 Penarikan Kesimpulan dan Pengujian Hipotesis Data Matriks Kualitas Air

Tugas Besar IF2220 Probabilitas dan Statistika

Disusun oleh:

1. 13520047 Hana Fathiyah
2. 13520128 Bayu Samudra

1.1 Requirement Modul Analisis

Pada tugas besar ini, kami menggunakan modul-modul sebagai berikut.

1. Numpy versi 1.22.3
2. Pandas versi 1.4.1
3. Seaborn versi 0.11.2
4. Matplotlib versi 3.5.1
5. Jupyterlab versi 3.3.2

Modul-modul tersebut dapat di-*install* dengan perintah sebagai berikut.

```
pip install -r requirements.txt
```

Berikut ini kami mencoba untuk melakukan *import library* (pustaka) tersebut.

[ ]:
```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import scipy

sns.set_theme()
```

1.2 Persiapan Data

Diberikan suatu *dataset* dengan nama `water_potability.csv`. Pada bagian ini, dataset tersebut akan di-*import* ke dalam sebuah variabel yang diberi nama `data`

[ ]:
```
data = pd.read_csv("water_potability.csv")
data.head()
```

[ ]:

	id	pH	Hardness	Solids	Chloramines	Sulfate	\
0	1	8.316766	214.373394	22018.417441	8.059332	356.886136	
1	2	9.092223	181.101509	17978.986339	6.546600	310.135738	
2	3	5.584087	188.313324	28748.687739	7.544869	326.678363	
3	4	10.223862	248.071735	28749.716544	7.513408	393.663396	
4	5	8.635849	203.361523	13672.091764	4.563009	303.309771	

	Conductivity	OrganicCarbon	Trihalomethanes	Turbidity	Potability
0	363.266516	18.436524	100.341674	4.628771	0
1	398.410813	11.558279	31.997993	4.075075	0
2	280.467916	8.399735	54.917862	2.559708	0
3	283.651634	13.789695	84.603556	2.672989	0
4	474.607645	12.363817	62.798309	4.401425	0

Berikut ini adalah metadata dari dataset yang telah diimport

[ ]:
```
data.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2010 entries, 0 to 2009
Data columns (total 11 columns):
 #   Column           Non-Null Count  Dtype
---  ------           --------------  -----
 0   id               2010 non-null   int64
 1   pH               2010 non-null   float64
 2   Hardness         2010 non-null   float64
 3   Solids           2010 non-null   float64
 4   Chloramines      2010 non-null   float64
 5   Sulfate          2010 non-null   float64
 6   Conductivity     2010 non-null   float64
 7   OrganicCarbon    2010 non-null   float64
 8   Trihalomethanes  2010 non-null   float64
 9   Turbidity        2010 non-null   float64
 10  Potability       2010 non-null   int64
dtypes: float64(9), int64(2)
memory usage: 172.9 KB
```

1.3 Nomor 1: Deskripsi Statistika

Pada nomor 1 ini, kami mencari deskripsi statistika (Descriptive Statistics) dari semua kolom pada data yang bersifat numerik, terdiri dari mean, median, modus, standar deviasi, variansi, range, nilai minimum, maksimum, kuartil, IQR, skewness dan kurtosis.

[ ]:
```
data.describe()
```

[ ]:
```
                id           pH     Hardness        Solids  Chloramines  \
count  2010.00000  2010.000000  2010.000000   2010.000000  2010.000000
mean   1005.50000     7.087193   195.969209  21904.673439     7.134322
std     580.38134     1.572803    32.643166   8625.397911     1.585214
min       1.00000     0.227499    73.492234    320.942611     1.390871
25%     503.25000     6.090785   176.740657  15614.412962     6.138326
50%    1005.50000     7.029490   197.203525  20926.882155     7.142014
75%    1507.75000     8.053006   216.447589  27170.534649     8.109933
max    2010.00000    14.000000   317.338124  56488.672413    13.127000

             Sulfate  Conductivity  OrganicCarbon  Trihalomethanes    Turbidity  \
count  2010.000000   2010.000000    2010.000000      2010.000000  2010.000000
mean    333.211376    426.476708      14.357940        66.400717     3.969497
std      41.211111     80.701872       3.325770        16.081109     0.780471
min     129.000000    201.619737       2.200000         8.577013     1.450000
25%     307.626986    366.619219      12.122530        55.949993     3.442882
50%     332.214113    423.438372      14.323286        66.482041     3.967374
75%     359.268147    482.209772      16.683562        77.294613     4.514663
max     481.030642    753.342620      27.006707       124.000000     6.494749

        Potability
count  2010.000000
mean      0.402985
std       0.490620
min       0.000000
25%       0.000000
50%       0.000000
75%       1.000000
max       1.000000
```

Data di atas menampilkan rata-rata (ditunjukkan dengan mean), median (ditunjukkan dengan baris 50%), standar deviasi (ditunjukkan dengan std), nilai minimum (ditunjukkan dengan min), nilai maksimum (ditunjukkan dengan max), dan kuartil (ditunjukkan dengan 25% (Q1), 50% (Q2), dan 75% (Q3)).

Selanjutnya akan dicari nilai variansi untuk setiap kolom pada dataset `water_potability.csv` tersebut

[ ]:
```
data.var()
```

[ ]:
```
id                3.368425e+05
pH                2.473709e+00
Hardness          1.065576e+03
Solids            7.439749e+07
Chloramines       2.512904e+00
Sulfate           1.698356e+03
Conductivity      6.512792e+03
OrganicCarbon     1.106075e+01
```

```
Trihalomethanes    2.586021e+02
Turbidity          6.091350e-01
Potability         2.407079e-01
dtype: float64
```

Selanjutnya, akan dicari nilai range untuk setiap kolom pada dataset `water_potability.csv` tersebut

[ ]:
```
data.max() - data.min()
```

[ ]:
```
id                 2009.000000
pH                   13.772501
Hardness            243.845890
Solids            56167.729801
Chloramines          11.736129
Sulfate             352.030642
Conductivity        551.722883
OrganicCarbon        24.806707
Trihalomethanes     115.422987
Turbidity             5.044749
Potability            1.000000
dtype: float64
```

Selanjutnya akan dicari nilai IQR untuk setiap kolom pada dataset `water_potability.csv` tersebut

[ ]:
```
q1 = data.quantile(0.25)
q3 = data.quantile(0.75)
q3 - q1
```

[ ]:
```
id                 1004.500000
pH                    1.962221
Hardness             39.706932
Solids            11556.121687
Chloramines           1.971607
Sulfate              51.641161
Conductivity        115.590553
OrganicCarbon         4.561031
Trihalomethanes      21.344620
Turbidity             1.071781
Potability            1.000000
dtype: float64
```

Selanjutnya akan dicari nilai skewness untuk setiap kolom pada dataset `water_potability.csv` tersebut

[ ]:
```
data.skew()
```

[ ]:
```
id                0.000000
pH                0.048535
Hardness         -0.085321
Solids            0.591011
Chloramines       0.013003
Sulfate          -0.045728
Conductivity      0.268012
OrganicCarbon    -0.020220
Trihalomethanes  -0.051383
Turbidity        -0.032266
Potability        0.395873
dtype: float64
```

Selanjutnya ditentukan nilai kurtosis untuk setiap kolom pada dataset `water_potability.csv` tersebut

[ ]:
```
data.kurtosis()
```

[ ]:
```
id               -1.200000
pH                0.626904
Hardness          0.525480
Solids            0.337320
Chloramines       0.549782
Sulfate           0.786854
Conductivity     -0.237206
OrganicCarbon     0.031018
Trihalomethanes   0.223017
Turbidity        -0.049831
Potability       -1.845122
dtype: float64
```

Selanjutnya akan dicari nilai modus untuk setiap kolom pada dataset `water_potability.csv` tersebut

[ ]:
```
data.mode()
```

[ ]:

	id	pH	Hardness	Solids	Chloramines	Sulfate	\
0	1	0.227499	73.492234	320.942611	1.390871	129.000000	
1	2	0.989912	77.459586	1198.943699	1.920271	180.206746	
2	3	1.431782	81.710895	1351.906979	2.397985	182.397370	
3	4	1.757037	94.091307	1372.091043	2.456014	187.170714	
4	5	1.985383	94.812545	2552.962804	2.458609	187.424131	
…	…	…	…	…	…	…	
2005	2006	11.568768	286.567991	50793.898917	12.580026	458.441072	
2006	2007	11.898078	287.975540	53735.899194	12.626900	460.107069	
2007	2008	12.246928	300.292476	55334.702799	12.653362	475.737460	
2008	2009	13.349889	306.627481	56351.396304	13.043806	476.539717	
2009	2010	14.000000	317.338124	56488.672413	13.127000	481.030642	

```
      Conductivity  OrganicCarbon  Trihalomethanes  Turbidity  Potability
0       201.619737       2.200000         8.577013   1.450000         0.0
1       210.319182       4.371899        14.343161   1.492207         NaN
2       233.907965       4.466772        15.684877   1.496101         NaN
3       245.859632       4.861631        16.291505   1.680554         NaN
4       252.968328       4.966862        17.527765   1.812529         NaN
…              …              …                …          …            …
2005    666.690618      23.569645       114.034946   6.307678         NaN
2006    669.725086      23.604298       114.208671   6.357439         NaN
2007    695.369528      23.917601       116.161622   6.389161         NaN
2008    708.226364      24.755392       120.030077   6.494249         NaN
2009    753.342620      27.006707       124.000000   6.494749         NaN

[2010 rows x 11 columns]
```

[ ]:
```
data.shape
```

[ ]:
```
(2010, 11)
```

Pada data di atas, terlihat bahwa nilai modus pada kolom selain kolom *portability* memiliki nilai lebih dari satu. Lebih jauh lagi, setiap kolom numerik selain kolom *portability* memiliki data yang unik sehingga semua nilai merupakan nilai modus.

1.4 Nomor 2: Visualisasi

Pada nomor ini, akan ditampilkan visualisasi distribusi plot untuk setiap kolom numerik

1.4.1 Data pH

Berikut ini adalah histogram untuk data pH pada dataset `water_portability.csv`

[ ]:
```
sns.histplot(data,x="pH")
```

[ ]:
```
<AxesSubplot:xlabel='pH', ylabel='Count'>
```

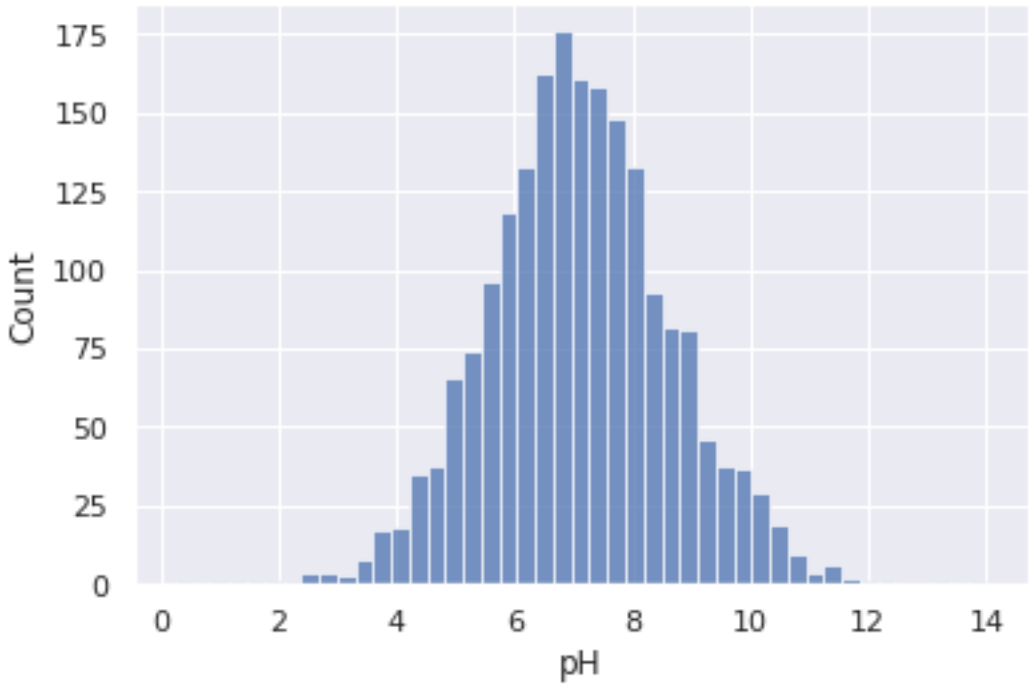

Berikut ini adalah boxplot untuk data pH pada dataset `water_portability.csv`

[ ]:
```
sns.boxplot(data = data, x = "pH")
```

[ ]:
```
<AxesSubplot:xlabel='pH'>
```

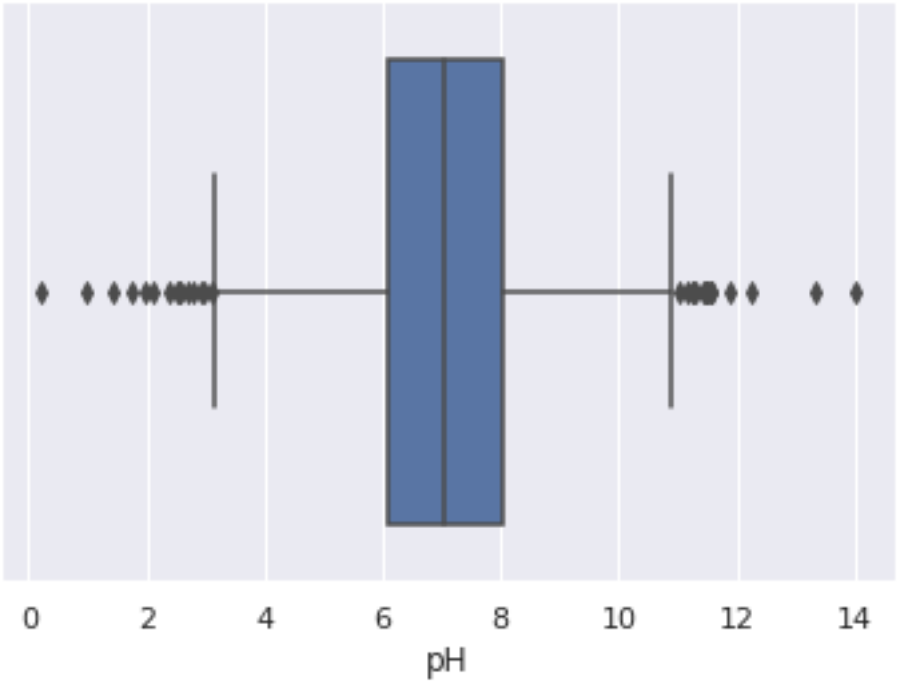

1.4.2 Data Hardness

Berikut ini adalah histogram untuk data Hardness pada dataset `water_portability.csv`

[ ]:
```
sns.histplot(data,x="Hardness")
```

[ ]:
```
<AxesSubplot:xlabel='Hardness', ylabel='Count'>
```

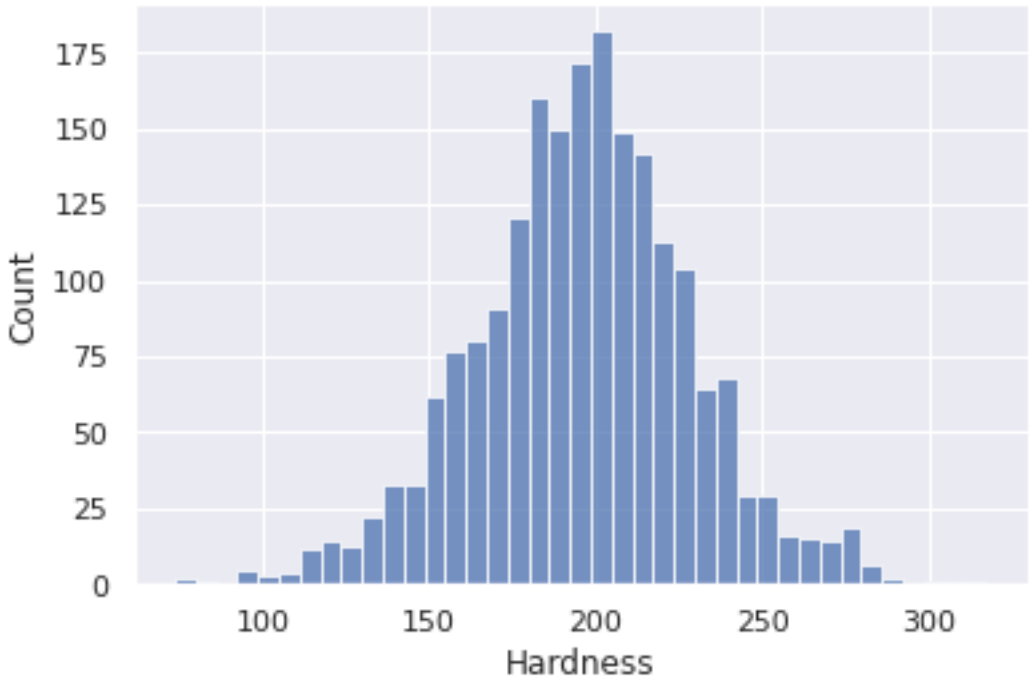

Berikut ini adalah boxplot untuk data Hardness pada dataset `water_portability.csv`

[ ]:
```
sns.boxplot(data = data, x = "Hardness")
```

[ ]:
```
<AxesSubplot:xlabel='Hardness'>
```

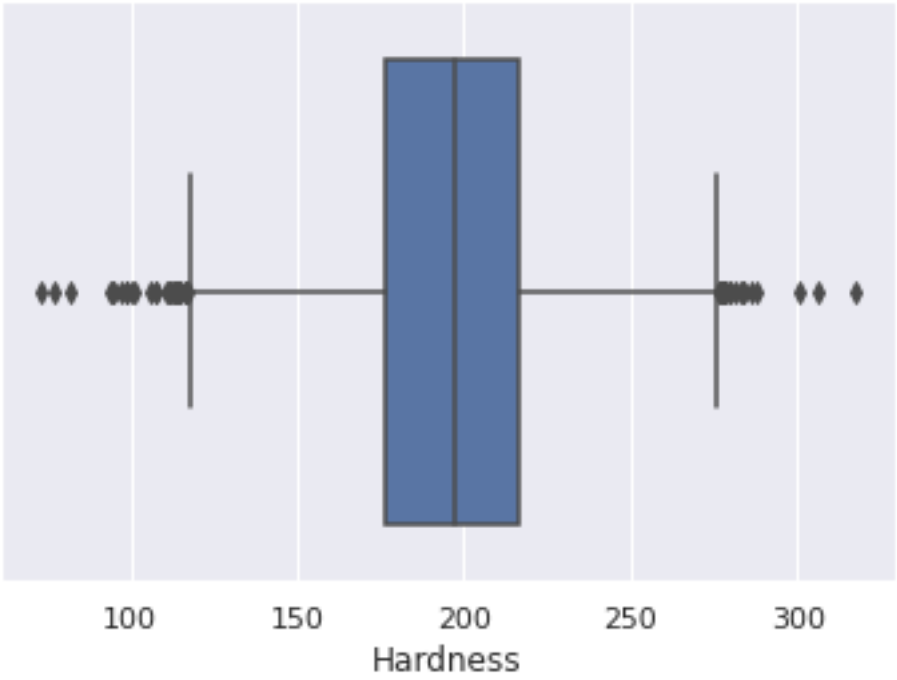

1.4.3 Data Solids

Berikut ini adalah histogram untuk data Solids pada dataset `water_portability.csv`

[ ]:
```
sns.histplot(data,x="Solids")
```

[ ]:
```
<AxesSubplot:xlabel='Solids', ylabel='Count'>
```

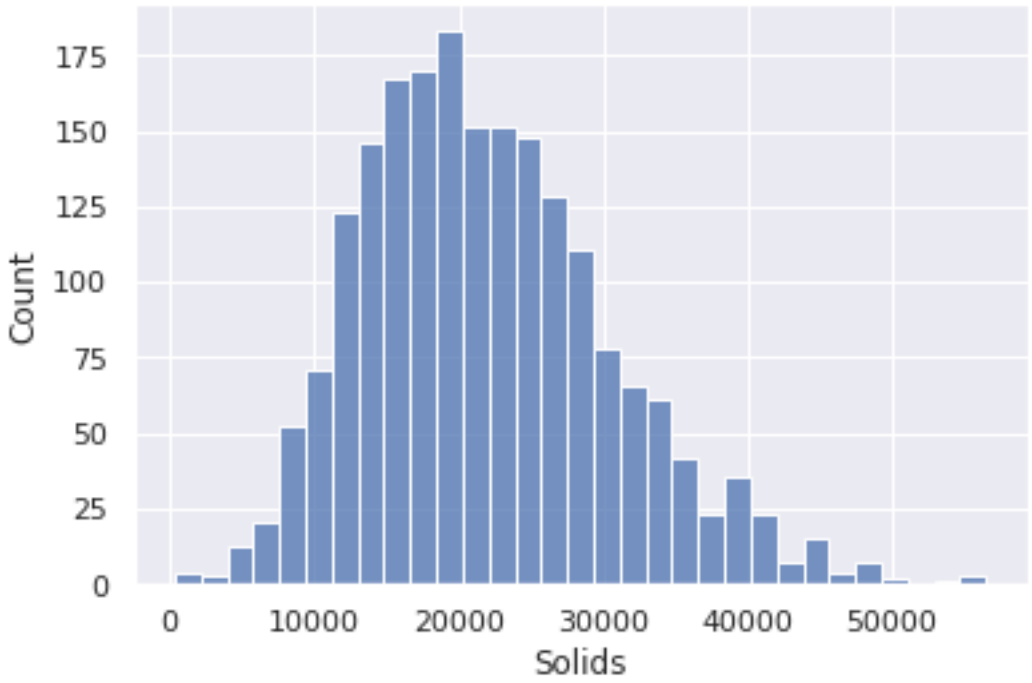

Berikut ini adalah boxplot untuk data Solids pada dataset `water_portability.csv`

[ ]:
```
sns.boxplot(data = data, x = "Solids")
```

[ ]:
```
<AxesSubplot:xlabel='Solids'>
```

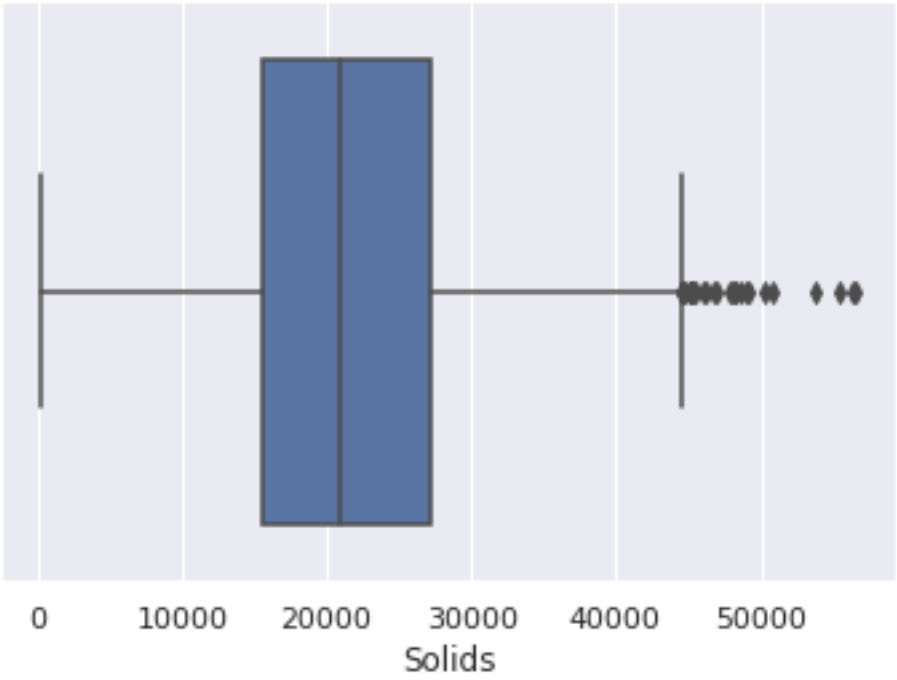

1.4.4 Data Chloramines

Berikut ini adalah histogram untuk data Chloramines pada dataset `water_portability.csv`

[ ]:
```
sns.histplot(data,x="Chloramines")
```

[ ]:
```
<AxesSubplot:xlabel='Chloramines', ylabel='Count'>
```

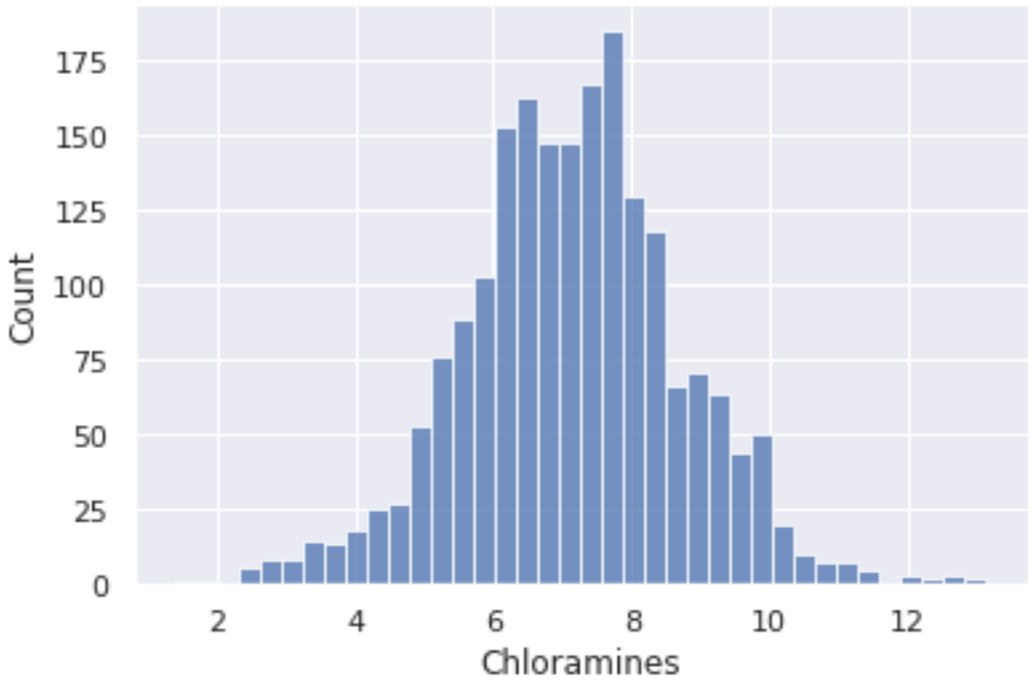

Berikut ini adalah boxplot untuk data Chloramines pada dataset `water_portability.csv`

[ ]:
```
sns.boxplot(data = data, x = "Chloramines")
```

[ ]:
```
<AxesSubplot:xlabel='Chloramines'>
```

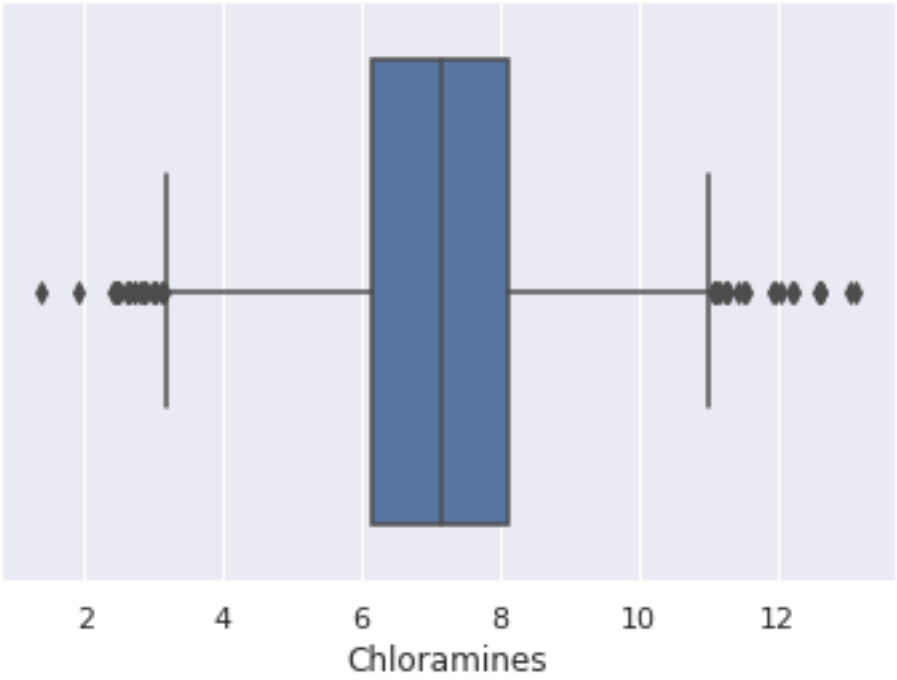

1.4.5 Data Sulfate

Berikut ini adalah histogram untuk data Sulfate pada dataset `water_portability.csv`

[ ]:
```
sns.histplot(data,x="Sulfate")
```

[ ]:
```
<AxesSubplot:xlabel='Sulfate', ylabel='Count'>
```

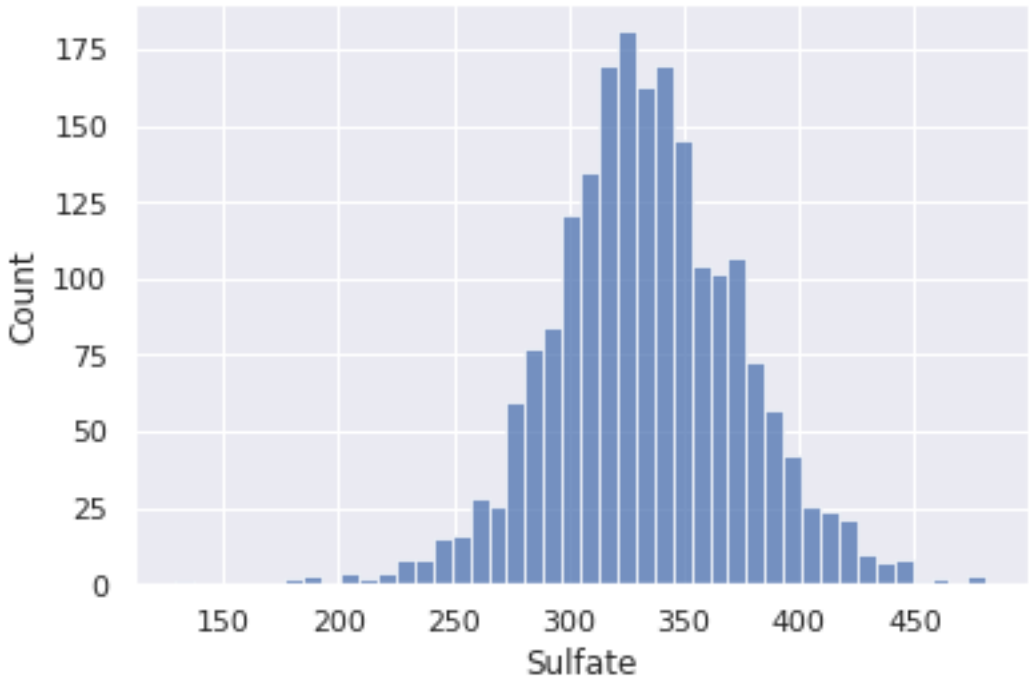

Berikut ini adalah boxplot untuk data Sulfate pada dataset `water_portability.csv`

[ ]:
```
sns.boxplot(data = data, x = "Sulfate")
```

[ ]:
```
<AxesSubplot:xlabel='Sulfate'>
```

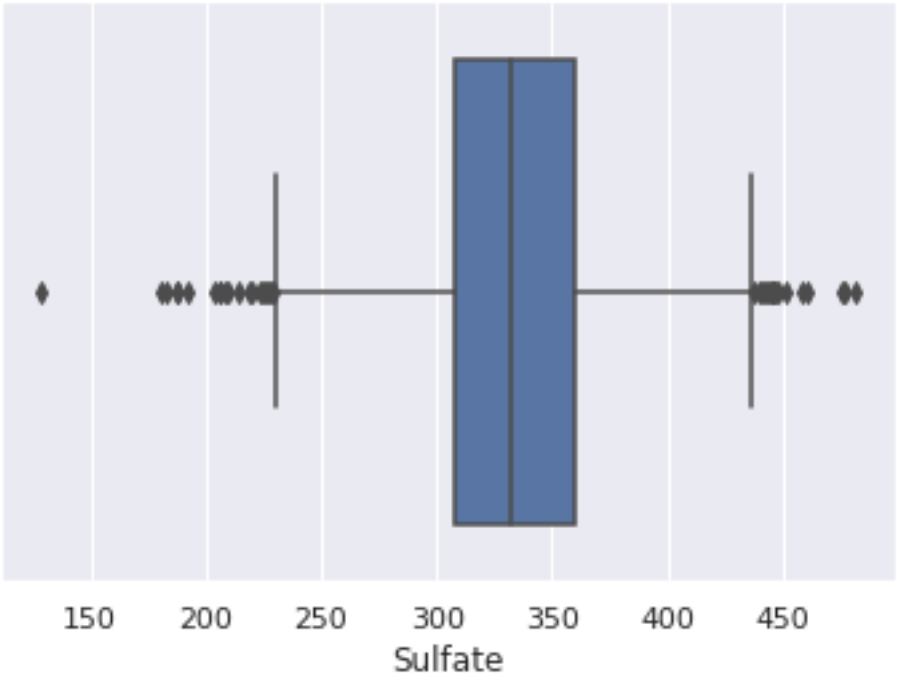

1.4.6 Data Conductivity

Berikut ini adalah histogram untuk data Conductivity pada dataset `water_portability.csv`

[ ]:
```
sns.histplot(data,x="Conductivity")
```

[ ]:
```
<AxesSubplot:xlabel='Conductivity', ylabel='Count'>
```

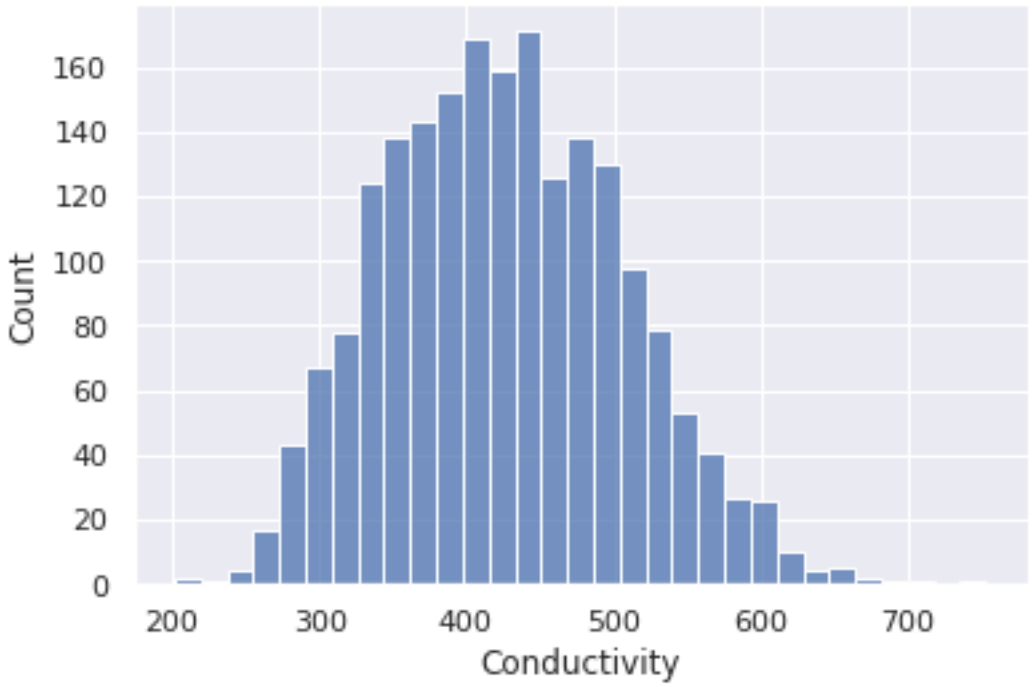

Berikut ini adalah boxplot untuk data Conductivity pada dataset `water_portability.csv`

[ ]:
```
sns.boxplot(data = data, x = "Conductivity")
```

[ ]:
```
<AxesSubplot:xlabel='Conductivity'>
```

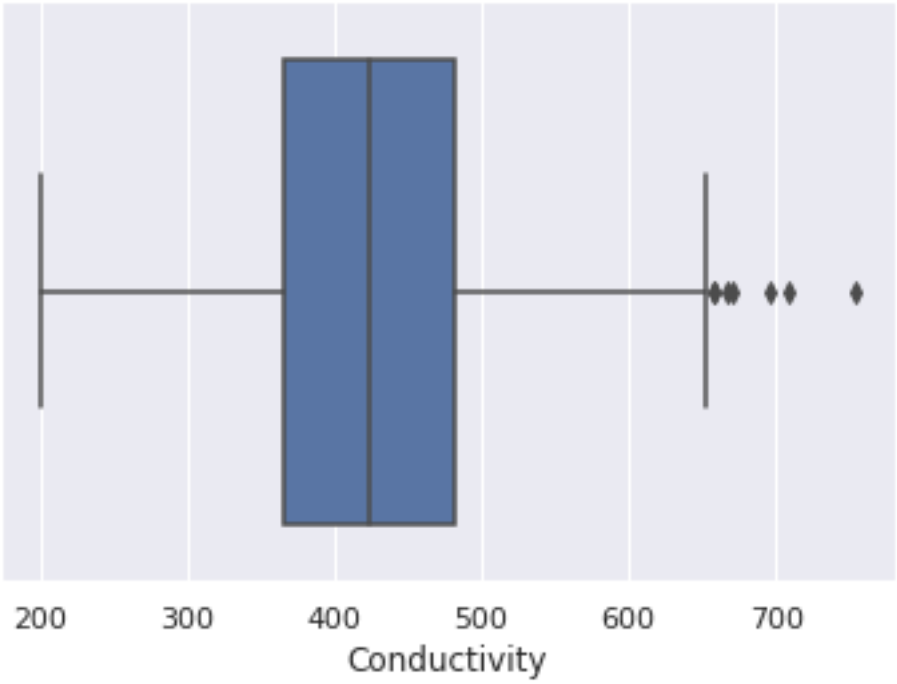

1.4.7 Data OrganicCarbon

Berikut ini adalah histogram untuk data OrganicCarbon pada dataset `water_portability.csv`

[ ]:
```
sns.histplot(data,x="OrganicCarbon")
```

[ ]:
```
<AxesSubplot:xlabel='OrganicCarbon', ylabel='Count'>
```

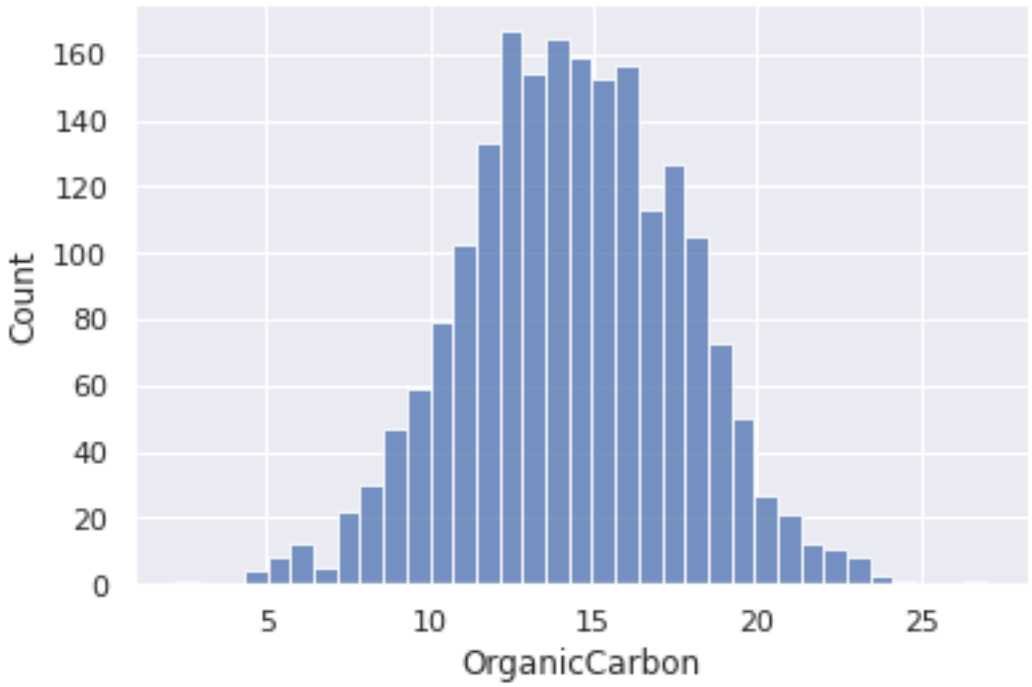

Berikut ini adalah boxplot untuk data OrganicCarbon pada dataset `water_portability.csv`

[ ]:
```
sns.boxplot(data = data, x = "OrganicCarbon")
```

[ ]:
```
<AxesSubplot:xlabel='OrganicCarbon'>
```

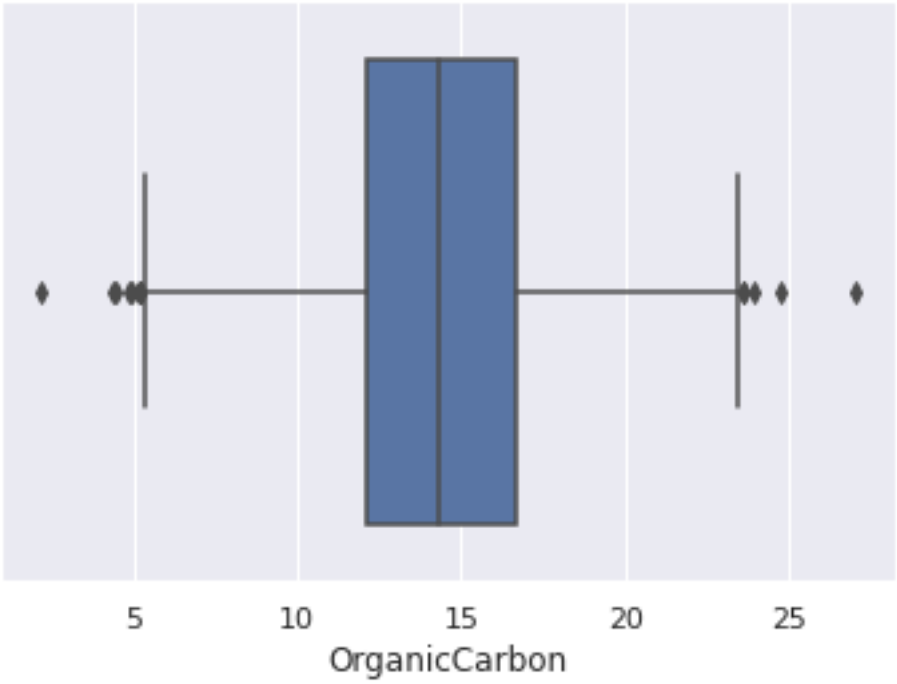

1.4.8 Data Trihalomethanes

Berikut ini adalah histogram untuk data Trihalomethanes pada dataset `water_portability.csv`

[ ]:
```
sns.histplot(data,x="Trihalomethanes")
```

[ ]:
```
<AxesSubplot:xlabel='Trihalomethanes', ylabel='Count'>
```

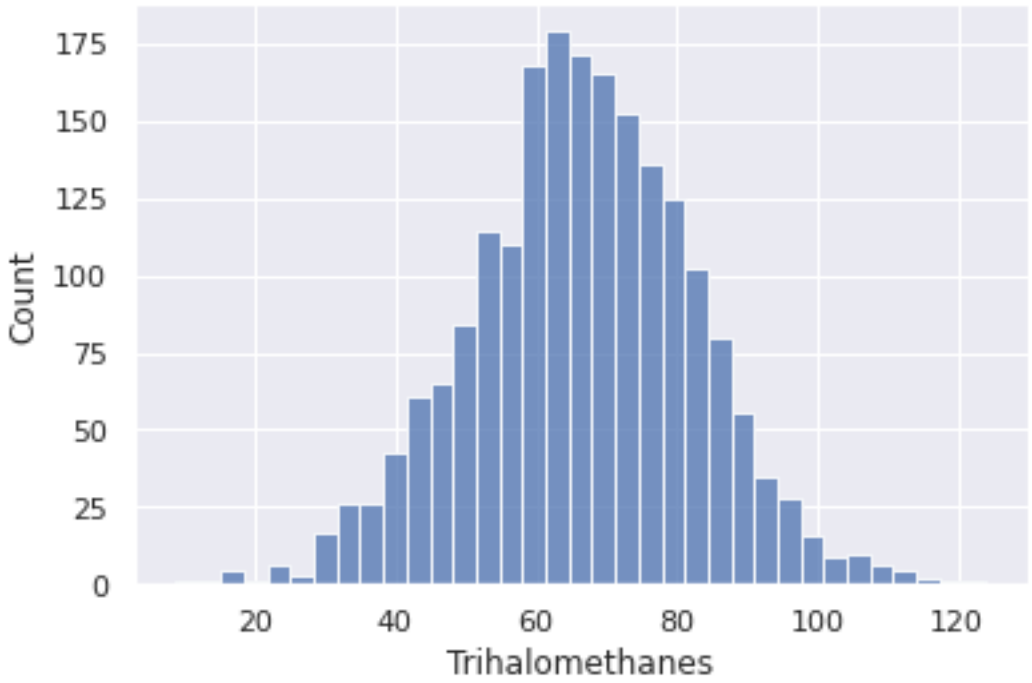

Berikut ini adalah boxplot untuk data Trihalomethanes pada dataset `water_portability.csv`

[ ]:
```
sns.boxplot(data = data, x = "Trihalomethanes")
```

[ ]:
```
<AxesSubplot:xlabel='Trihalomethanes'>
```

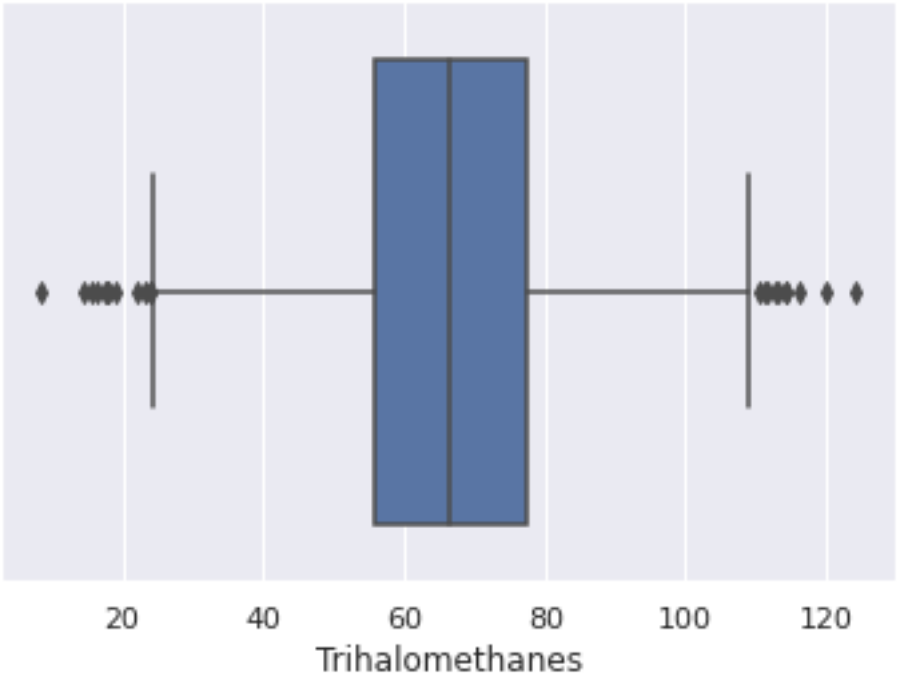

1.4.9 Data Turbidity

Berikut ini adalah histogram untuk data Turbidity pada dataset `water_portability.csv`

[ ]:
```
sns.histplot(data,x="Turbidity")
```

[ ]:
```
<AxesSubplot:xlabel='Turbidity', ylabel='Count'>
```

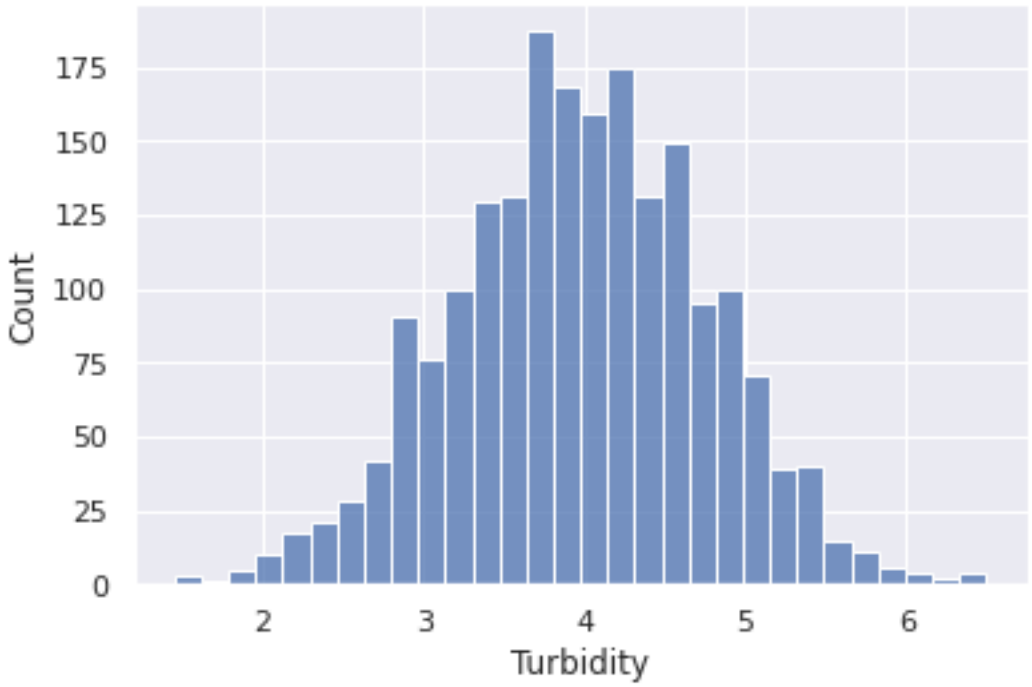

Berikut ini adalah boxplot untuk data Turbidity pada dataset `water_portability.csv`

[ ]:
```
sns.boxplot(data = data, x = "Turbidity")
```

[ ]:
```
<AxesSubplot:xlabel='Turbidity'>
```

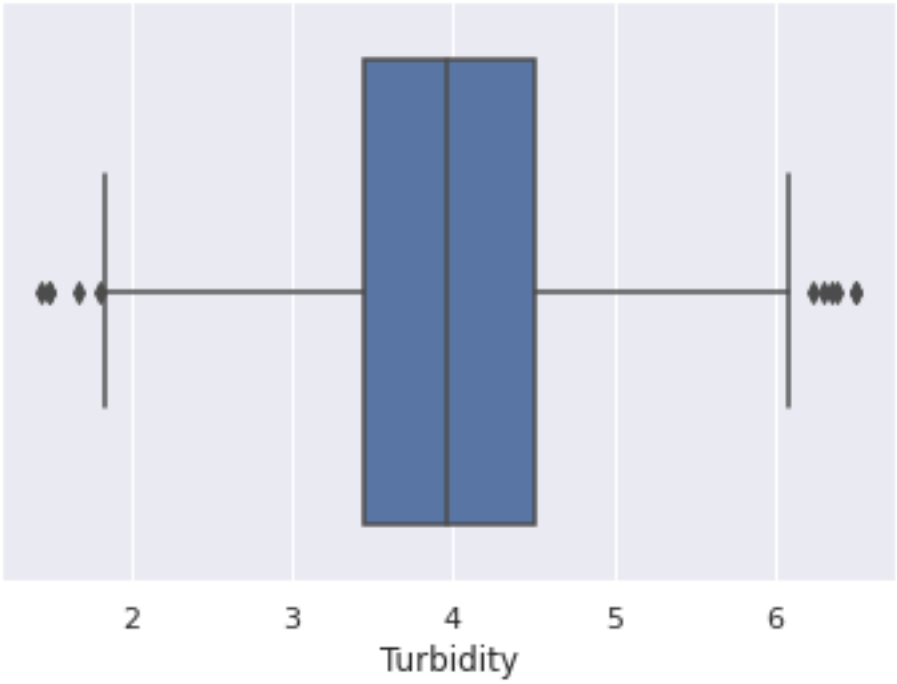

1.5 Nomor 3: Tes Distribusi Normal

Pada bagian ini, akan dites apakah setiap kolom berdistribusi normal atau tidak. Kolom yang akan dianalisis adalah kolom numerik, yaiur kolom 2 sampai dengan kolom 10.

1.5.1 Metode Tes

Metode pengetesan akan dilakukan dengan dua cara, yaitu metode grafik dan statistik.

Metode Grafik Pada metode grafik, kami akan menggunakan QQ Plot dengan histogram. Pada tahap ini kami hanya mengamati seberapa dekat suatu kolom dengan normalnya.

Pembuatan grafik QQ dapat dilakukan dengan menjadikan setiap data merupakan quantiles dari semua data. Setelah itu, setiap quantiles dihitung korespondensinya terhadap tabel normal. Setelah itu akan dilakukan plotting menggunakan scatter plot dan dibuat regresinya. Apabila kebanyakan titik berada pada garis, maka data berdistribusi normal.

Berikut ini adalah fungsi yang akan membantu membuat QQ Plot

[ ]:
```
def QQ_Plot(data):
  dataset = np.sort(data)
  norm = scipy.stats.norm()
  normalDataset = np.array([
    norm.ppf((i+0.5)/len(dataset)) for i in range(len(dataset))
  ])
```

```
sns.regplot(x=normalDataset, y=dataset)
plt.xlabel("Normal Quantiles")
plt.ylabel("Data Quantiles")
```

Metode Statistik Pada metode statistik, kami menggunakan D'Agostino-Pearson Omnibus test untuk pengujian statistik. Pengetesan akan dilakukan dengan menggunakan pengujian hipotestis.

Berikut ini adalah hipotesinya:

1. Hipotesis nol (H_0) dari pengetesan ini adalah kolom berdistribusi normal.
2. Hipotesis slternatif (H_1) dari pengetesan ini adalah kolom tidak berdistribusi normal.

Tingkat signifikansi yang digunakan adalah $\alpha = 0.05$

[ ]:
```
alpha = 0.05
```

Berikut ini adalah langkah pengujian statistik yang dilakukan:

1. Kurtosis dan juga skewness dari sebuah kolom perlu dihitung terlebih dahulu.
2. Menghitung error standard untuk skewness. Rumus untuk perhitungan skewness standard error adalah sebagai berikut:

$$s.e = \sqrt{\frac{6n(n-1)}{(n-2)(n+1)(n+3)}}$$

3. Menghitung error standar untuk kurtosis. Rumus untuk melakukan perhitungan ini adalah sebagai berikut:

$$k.e = 2 \cdot (s.e) \cdot \sqrt{\frac{n^2-1}{(n-3)(n+5)}}$$

4. Perlu dihtung standar score untu skewness. Berikut ini adalah rumusnya:

$$z_s = \frac{Sk}{s.e}$$

5. Perlu dihitung standar error untuk kurtosis. Berikut ini adalah rumusnya:

$$z_k = \frac{Kur}{k.e}$$

6. Jumlah kuadrat dari Nilai dari standar skor untuk skewness dan kurtosis dapat didekatkan dengan distribusi chi-square derajat dua.

$$z_x^2 + z_k^2 \approx \chi_\alpha^2$$

   Oleh karena itu, nilai p dapat dihitung dengan mencari distribusi dari chi-square berderajat 2.

Proses diatas dapat dilakukan dengan menggunakan library dari scipy, yaitu `scipy.stat.normaltest`.

Pada langkah terakhir, akan diperiksa apakah nilai p kurang dari level signifikansi. Bila kurang, maka hipotesis H_0 dapat ditolak.

1.5.2 Data pH

Pada bagian ini, akan dicoba untuk melakukan test normal pada data pH. Berikut ini adalah histogram dan juga QQ plot dari data pH.

[ ]:
```
QQ_Plot(data["pH"])
plt.title("QQ Plot pH")
```

[ ]:
```
Text(0.5, 1.0, 'QQ Plot pH')
```

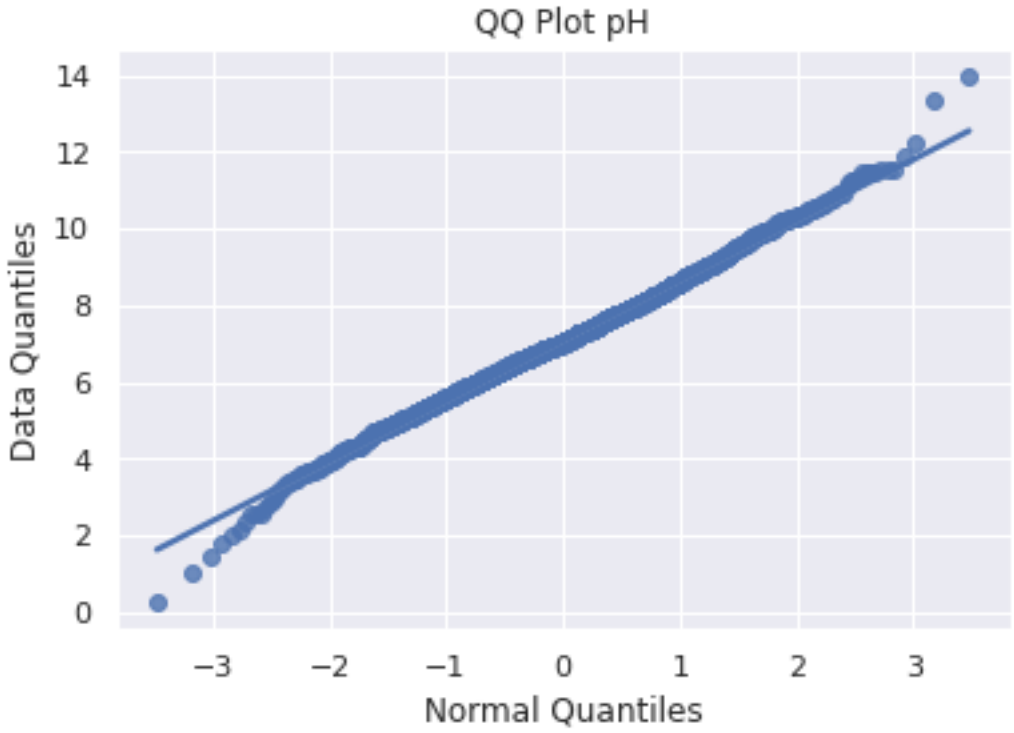

[ ]:
```
sns.histplot(data=data, x="pH", kde=True)
plt.title("Histogram data pH")
```

[ ]:
```
Text(0.5, 1.0, 'Histogram data pH')
```

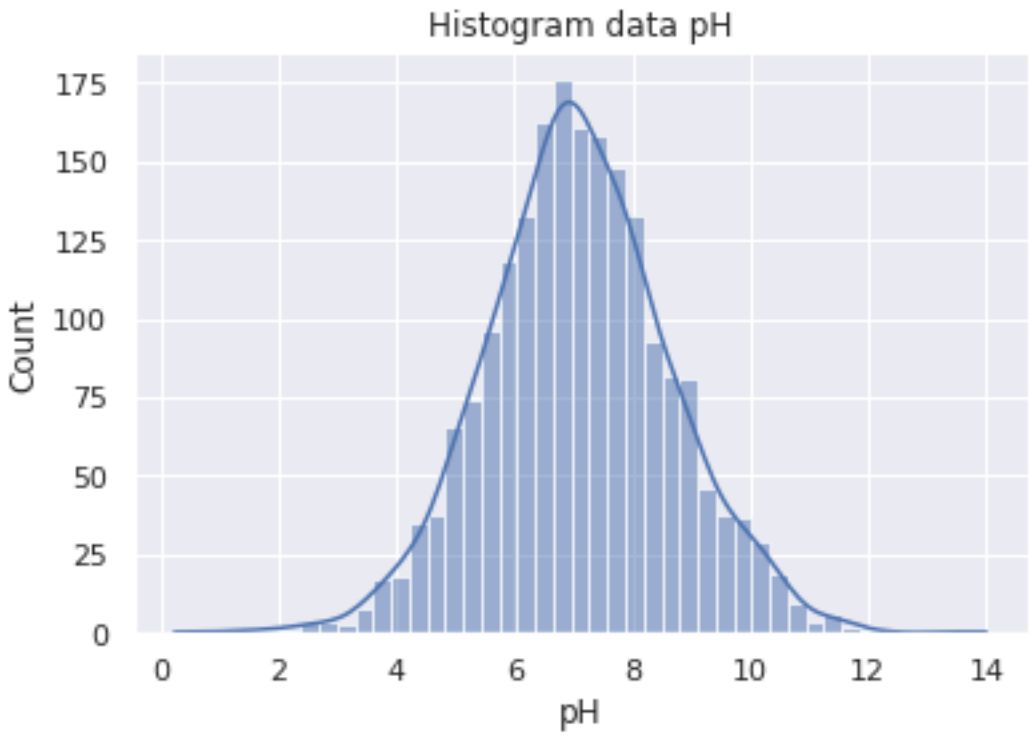

Dari kedua grafik diatas, data pH terlihat data bisa jadi tidak berdistribusi normal. Hal ini terlihat pada ujung kiri dan ujung kanan QQ Plot yang menjauh dari garis.

Pada bagian selanjutnya, data akan diuji menggunakan pendekatan statistik.

[ ]:
```
_, p = scipy.stats.normaltest(data["pH"])
print(f"p = {p}")

if p < alpha:
  print("Data tidak berdistribusi normal")
else:
  print("Data berdistribusi normal")
```

```
p = 2.6514813346797777e-05
Data tidak berdistribusi normal
```

1.5.3 Data Hardness

Pada bagian ini, akan dicoba untuk melakukan test normal pada data Hardness. Berikut ini adalah histogram dan juga QQ plot dari data Hardness.

[ ]:
```
QQ_Plot(data["Hardness"])
plt.title("QQ Plot Hardness")
```

[ ]:
```
Text(0.5, 1.0, 'QQ Plot Hardness')
```

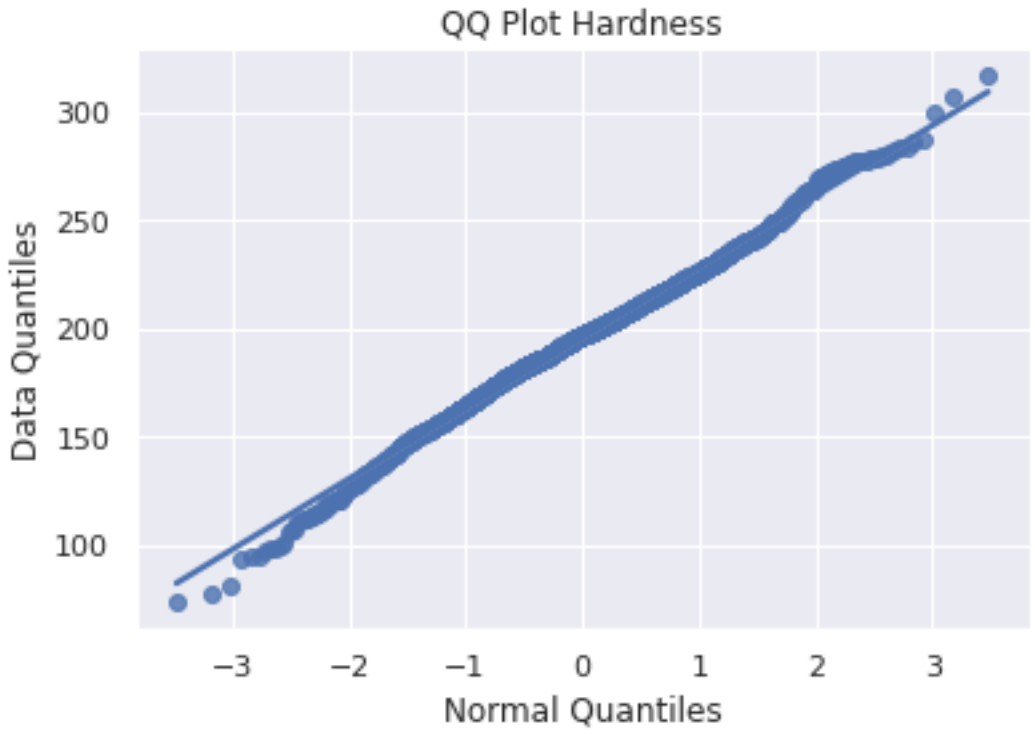

[ ]:
```
sns.histplot(data=data, x="Hardness", kde=True)
plt.title("Histogram data Hardness")
```

[ ]:
```
Text(0.5, 1.0, 'Histogram data Hardness')
```

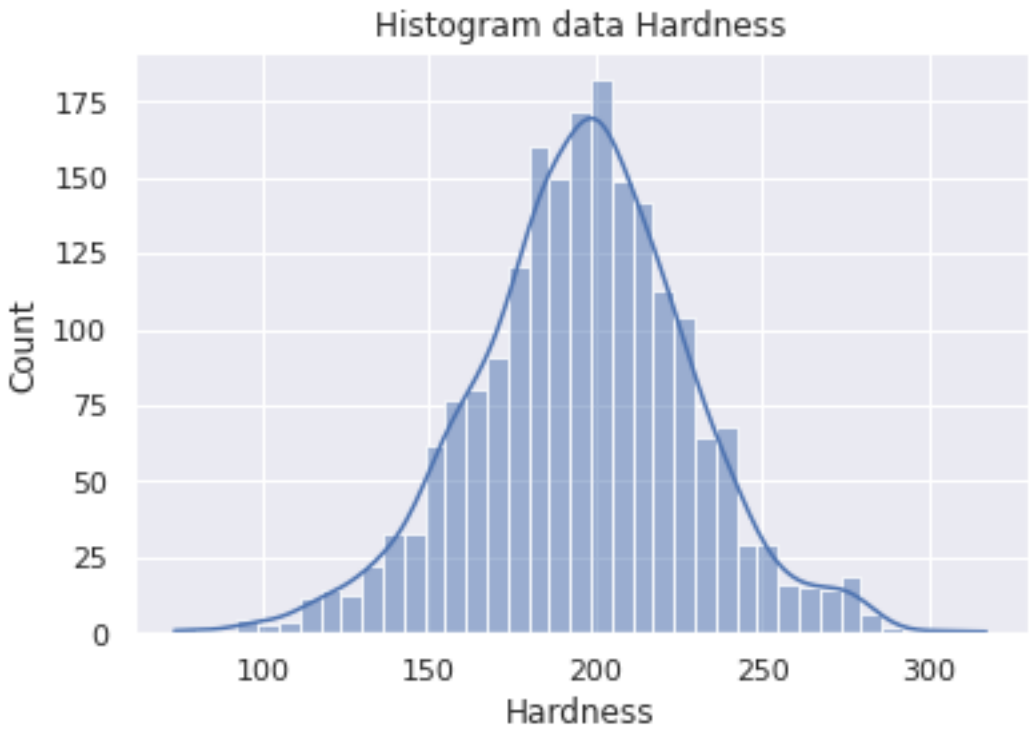

Dari kedua grafik diatas, data pH terlihat data bisa jadi tidak berdistribusi normal. Hal ini terlihat pada ujung kiri dan ujung kanan QQ Plot yang menjauh dari garis.

Pada bagian selanjutnya, data akan diuji menggunakan pendekatan statistik.

[ ]:
```
_, p = scipy.stats.normaltest(data["Hardness"])
print(f"p = {p}")

if p < alpha:
  print("Data tidak berdistribusi normal")
else:
  print("Data berdistribusi normal")
```

```
p = 0.00013442428699593753
Data tidak berdistribusi normal
```

Berdasarkan pengujian statistik, terlihat bahwa data tidak berdistribusi normal. Hal ini dikarenakan nilai $p < 0.05$ sehingga hipotesis H_0 dapat ditolak.

Kesimpulan dari pengujian ini adalah data Hardness bukan merupakan data yang berdistribusi normal

1.5.4 Data Solids

Pada bagian ini, akan dicoba untuk melakukan test normal pada data Solids. Berikut ini adalah histogram dan juga QQ plot dari data Solids.

[ ]:
```
QQ_Plot(data["Solids"])
plt.title("QQ Plot Solids")
```

[ ]:
```
Text(0.5, 1.0, 'QQ Plot Solids')
```

[ ]:
```
sns.histplot(data=data, x="Solids", kde=True)
plt.title("Histogram data Solids")
```

[ ]:
```
Text(0.5, 1.0, 'Histogram data Solids')
```

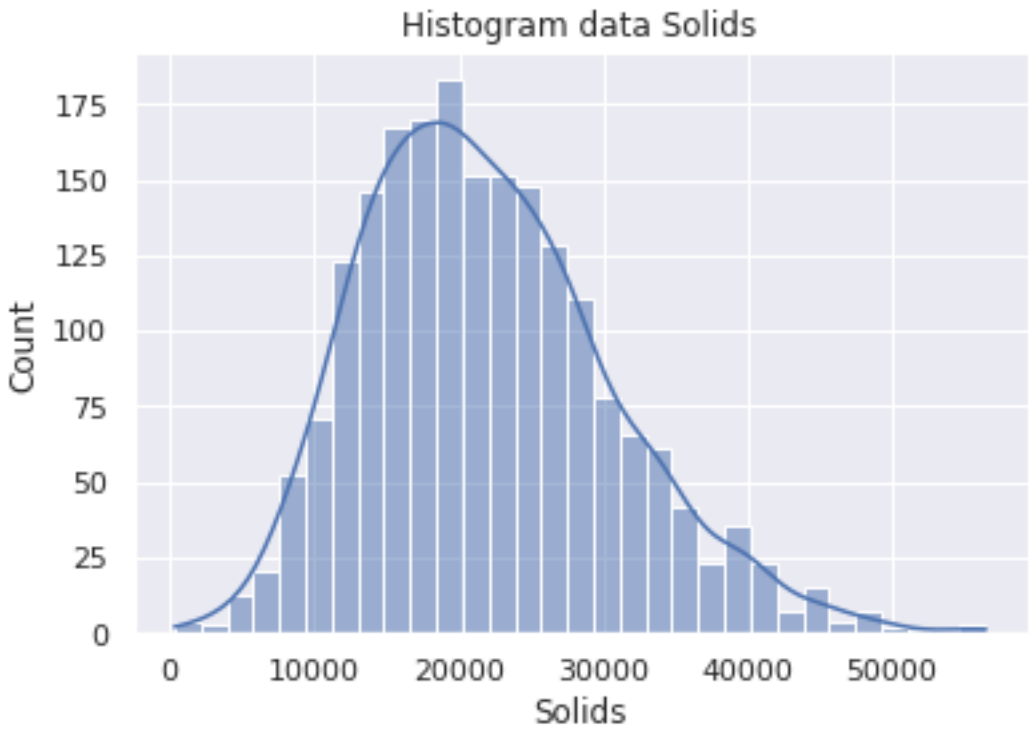

Dari kedua grafik diatas, data pH terlihat data bisa jadi tidak berdistribusi normal. Hal ini terlihat cukup banyak titik yang tidak berada pada garis.

Pada bagian selanjutnya, data akan diuji menggunakan pendekatan statistik.

[ ]:
```
_, p = scipy.stats.normaltest(data["Solids"])
print(f"p = {p}")

if p < alpha:
  print("Data tidak berdistribusi normal")
else:
  print("Data berdistribusi normal")
```

```
p = 2.0796613688739523e-24
Data tidak berdistribusi normal
```

Berdasarkan pengujian statistik, terlihat bahwa data tidak berdistribusi normal. Hal ini dikarenakan nilai $p < 0.05$ sehingga hipotesis H_0 dapat ditolak.

Kesimpulan dari pengujian ini adalah data Solids bukan merupakan data yang berdistribusi normal

1.5.5 Data Chloramines

Pada bagian ini, akan dicoba untuk melakukan test normal pada data Chloramines. Berikut ini adalah histogram dan juga QQ plot dari data Chloramines.

[ ]:
```
QQ_Plot(data["Chloramines"])
plt.title("QQ Plot Chloramines")
```

[ ]:
```
Text(0.5, 1.0, 'QQ Plot Chloramines')
```

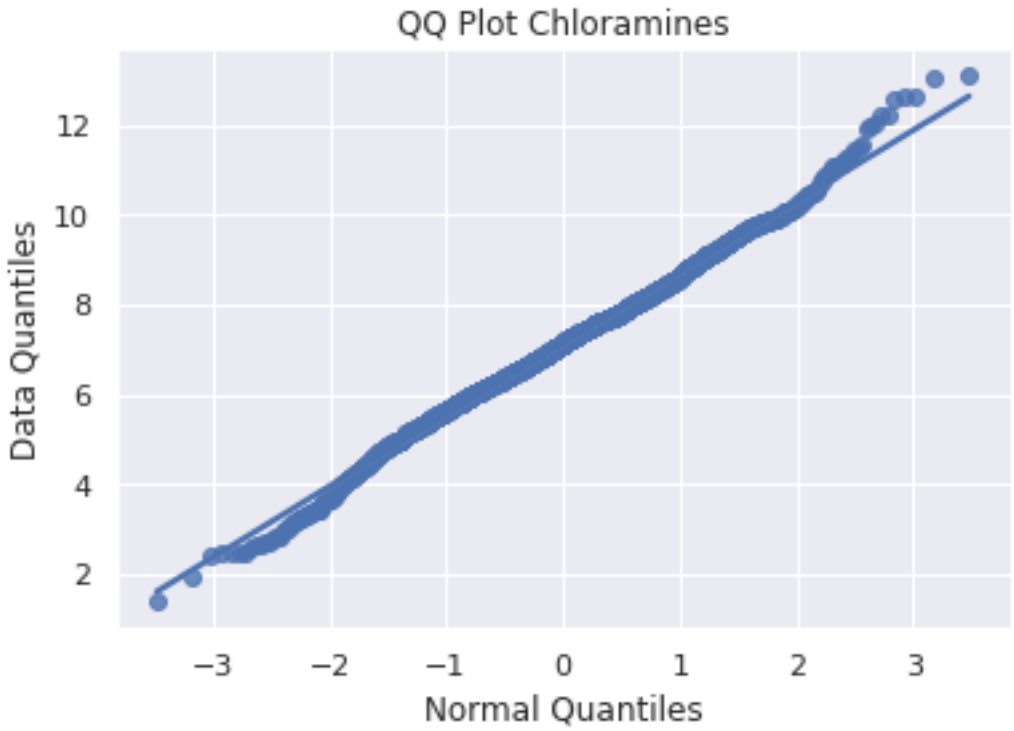

[ ]:
```
sns.histplot(data=data, x="Chloramines", kde=True)
plt.title("Histogram data Chloramines")
```

[ ]:
```
Text(0.5, 1.0, 'Histogram data Chloramines')
```

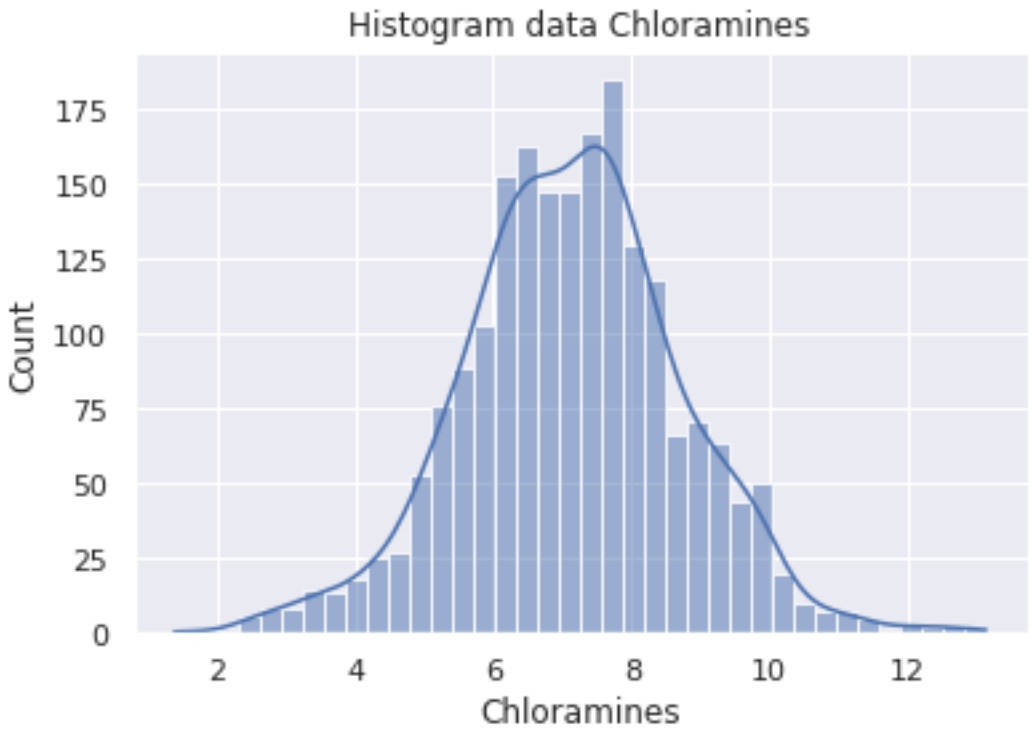

Dari kedua grafik diatas, data Chloramines terlihat data bisa jadi tidak berdistribusi normal. Hal ini terlihat cukup banyak titik yang tidak berada pada garis.

Pada bagian selanjutnya, data akan diuji menggunakan pendekatan statistik.

[ ]:
```
_, p = scipy.stats.normaltest(data["Chloramines"])
print(f"p = {p}")

if p < alpha:
  print("Data tidak berdistribusi normal")
else:
  print("Data berdistribusi normal")
```

```
p = 0.0002504831654753917
Data tidak berdistribusi normal
```

Berdasarkan pengujian statistik, terlihat bahwa data tidak berdistribusi normal. Hal ini dikarenakan nilai $p < 0.05$ sehingga hipotesis H_0 dapat ditolak.

Kesimpulan dari pengujian ini adalah data Chloramines bukan merupakan data yang berdistribusi normal

1.5.6 Data Sulfate

Pada bagian ini, akan dicoba untuk melakukan test normal pada data Sulfate. Berikut ini adalah histogram dan juga QQ plot dari data Sulfate.

[ ]:
```
QQ_Plot(data["Sulfate"])
plt.title("QQ Plot Sulfate")
```

[ ]:
```
Text(0.5, 1.0, 'QQ Plot Sulfate')
```

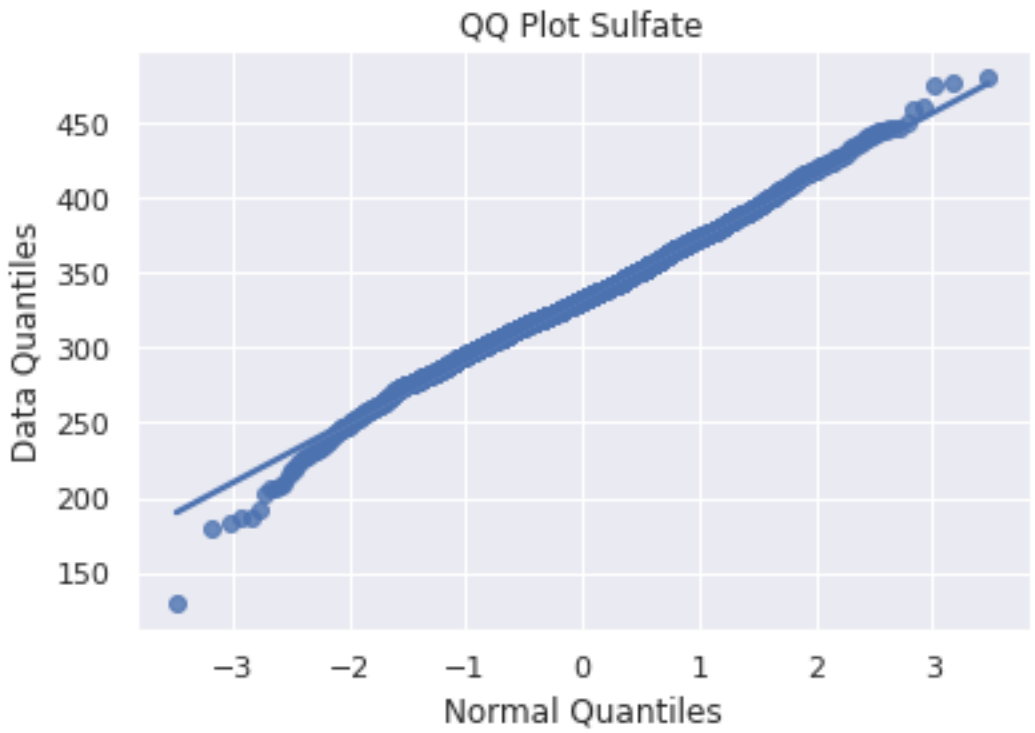

[ ]:
```
sns.histplot(data=data, x="Sulfate", kde=True)
plt.title("Histogram data Sulfate")
```

[ ]:
```
Text(0.5, 1.0, 'Histogram data Sulfate')
```

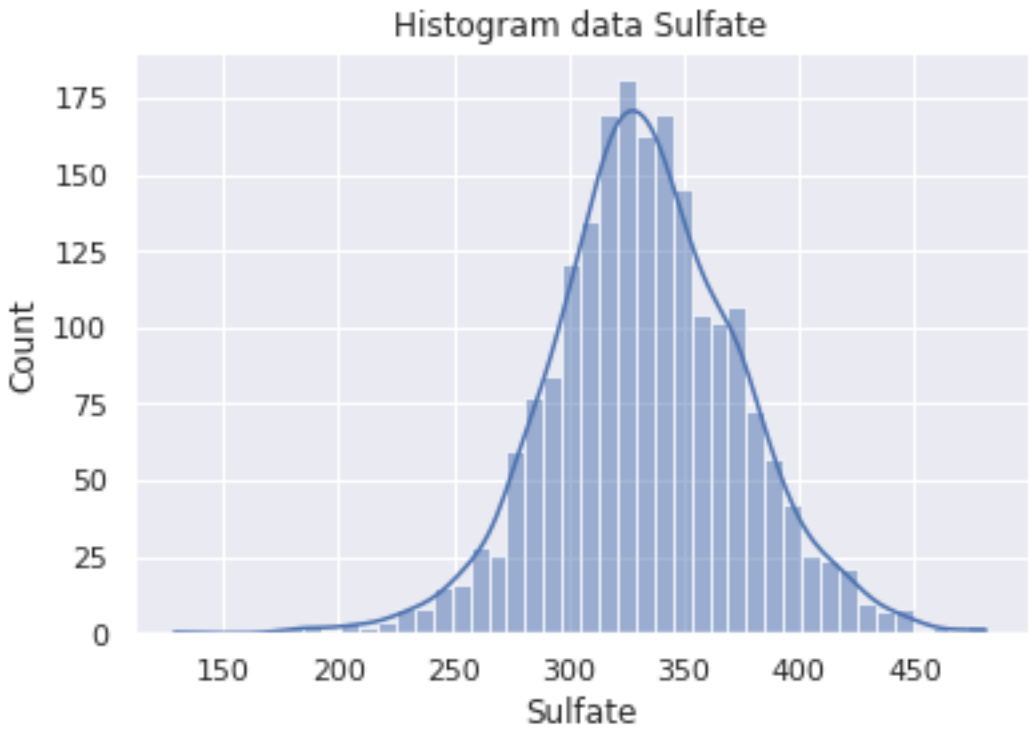

Dari kedua grafik diatas, data Chloramines terlihat data bisa jadi tidak berdistribusi normal. Hal ini terlihat data miring ke sumbu x negatif pada histogram dan pada ujung-ujung plot QQ menjauh terhadap garis.

Pada bagian selanjutnya, data akan diuji menggunakan pendekatan statistik.

[ ]:
```
_, p = scipy.stats.normaltest(data["Sulfate"])
print(f"p = {p}")

if p < alpha:
  print("Data tidak berdistribusi normal")
else:
  print("Data berdistribusi normal")
```

```
p = 4.4255936678013136e-07
Data tidak berdistribusi normal
```

Berdasarkan pengujian statistik, terlihat bahwa data tidak berdistribusi normal. Hal ini dikarenakan nilai $p < 0.05$ sehingga hipotesis H_0 dapat ditolak.

Kesimpulan dari pengujian ini adalah data Sulfate bukan merupakan data yang berdistribusi normal

1.5.7 Data Conductivity

Pada bagian ini, akan dicoba untuk melakukan test normal pada data Conductivity. Berikut ini adalah histogram dan juga QQ plot dari data Conductivity.

[ ]:
```
QQ_Plot(data["Conductivity"])
plt.title("QQ Plot Conductivity")
```

[ ]:
```
Text(0.5, 1.0, 'QQ Plot Conductivity')
```

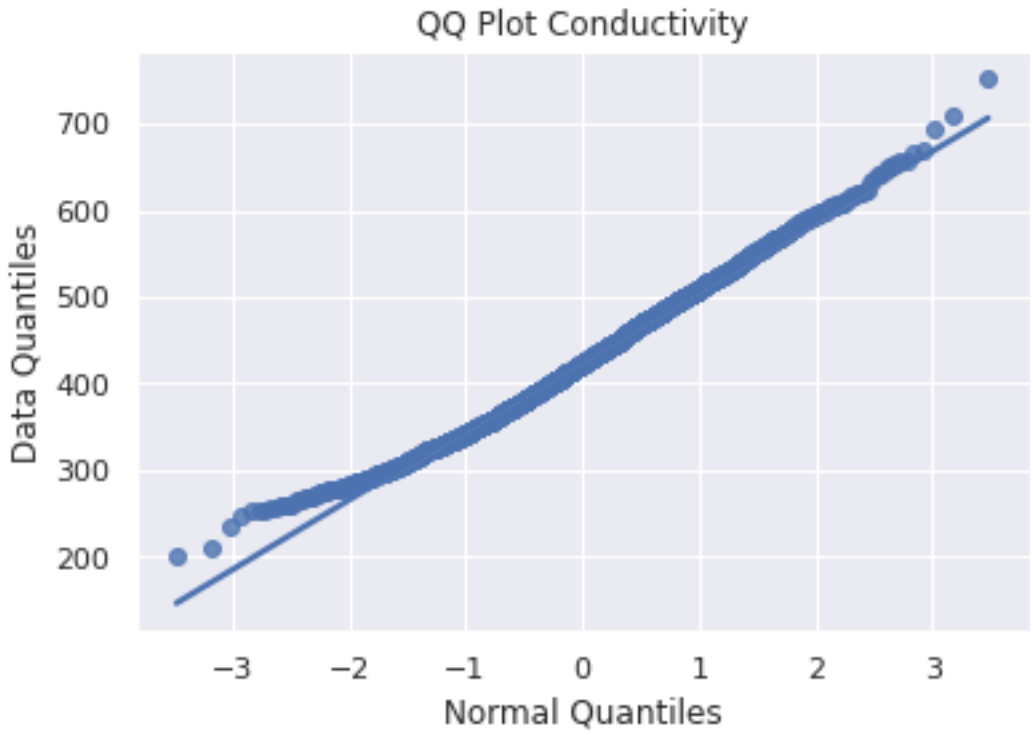

[ ]:
```
sns.histplot(data=data, x="Conductivity", kde=True)
plt.title("Histogram data Conductivity")
```

[ ]:
```
Text(0.5, 1.0, 'Histogram data Conductivity')
```

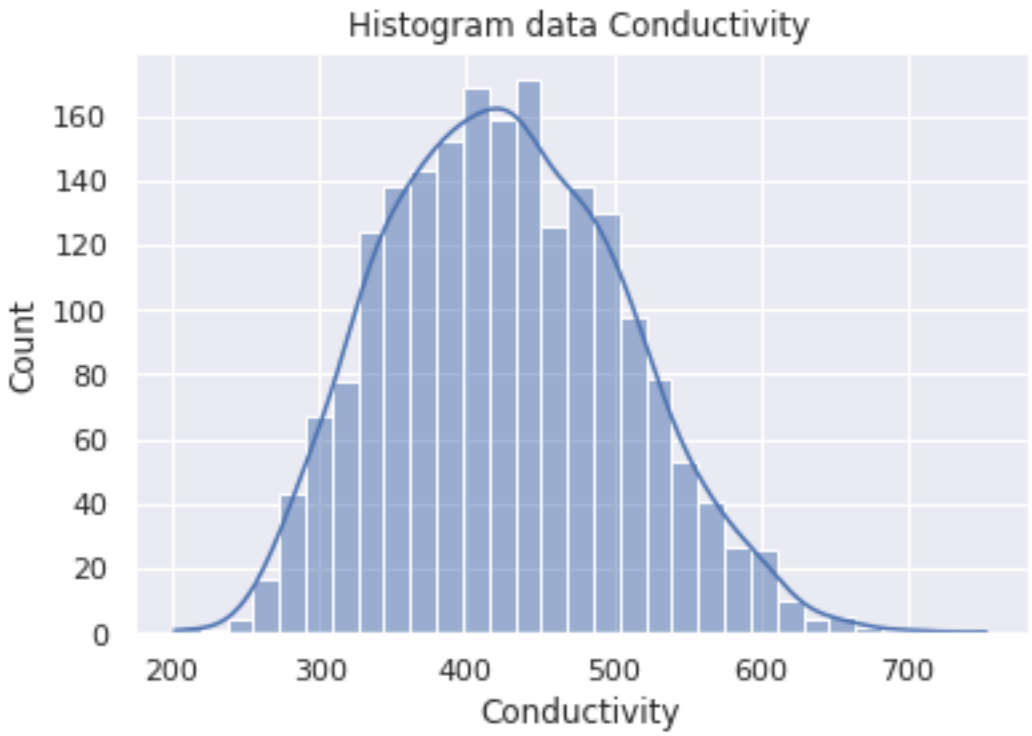

Dari kedua grafik diatas, data Chloramines terlihat data bisa jadi tidak berdistribusi normal. Hal ini terlihat data miring ke sumbu x positif pada histogram dan pada ujung-ujung plot QQ menjauh terhadap garis.

Pada bagian selanjutnya, data akan diuji menggunakan pendekatan statistik.

[ ]:
```
_, p = scipy.stats.normaltest(data["Conductivity"])
print(f"p = {p}")

if p < alpha:
  print("Data tidak berdistribusi normal")
else:
  print("Data berdistribusi normal")
```

```
p = 4.3901807828784666e-07
Data tidak berdistribusi normal
```

Berdasarkan pengujian statistik, terlihat bahwa data tidak berdistribusi normal. Hal ini dikarenakan nilai $p < 0.05$ sehingga hipotesis H_0 dapat ditolak.

Kesimpulan dari pengujian ini adalah data Conductivity bukan merupakan data yang berdistribusi normal

1.5.8 Data OrganicCarbon

Pada bagian ini, akan dicoba untuk melakukan test normal pada data OrganicCarbon. Berikut ini adalah histogram dan juga QQ plot dari data OrganicCarbon.

[ ]:
```
QQ_Plot(data["OrganicCarbon"])
plt.title("QQ Plot OrganicCarbon")
```

[ ]:
```
Text(0.5, 1.0, 'QQ Plot OrganicCarbon')
```

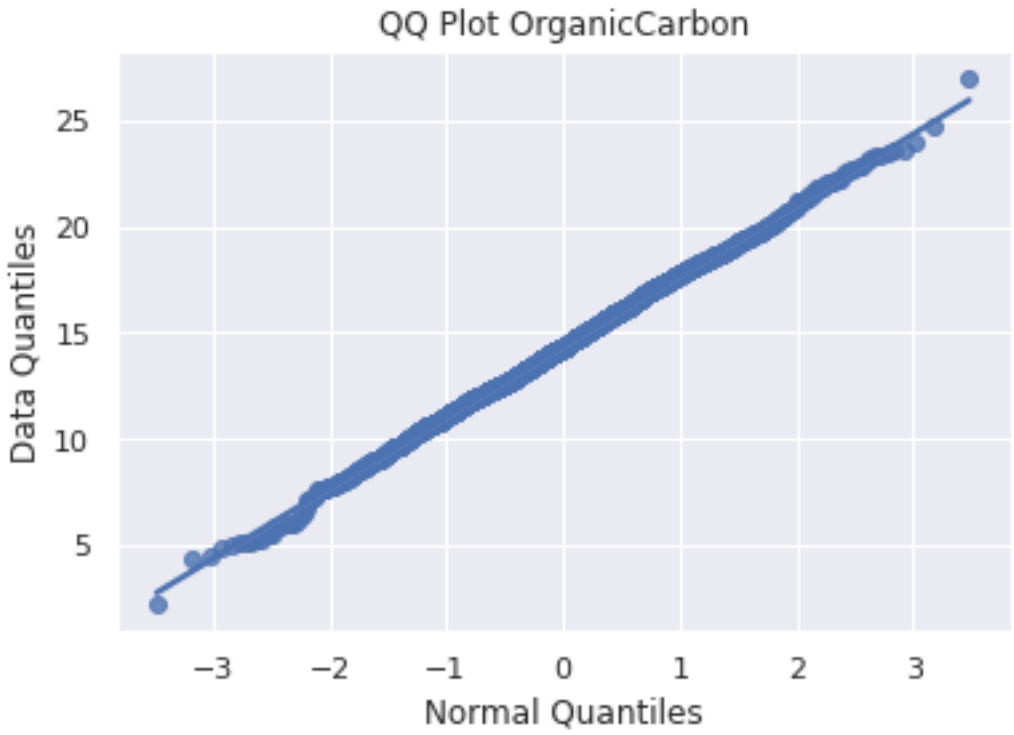

[ ]:
```
sns.histplot(data=data, x="OrganicCarbon", kde=True)
plt.title("Histogram data OrganicCarbon")
```

[ ]:
```
Text(0.5, 1.0, 'Histogram data OrganicCarbon')
```

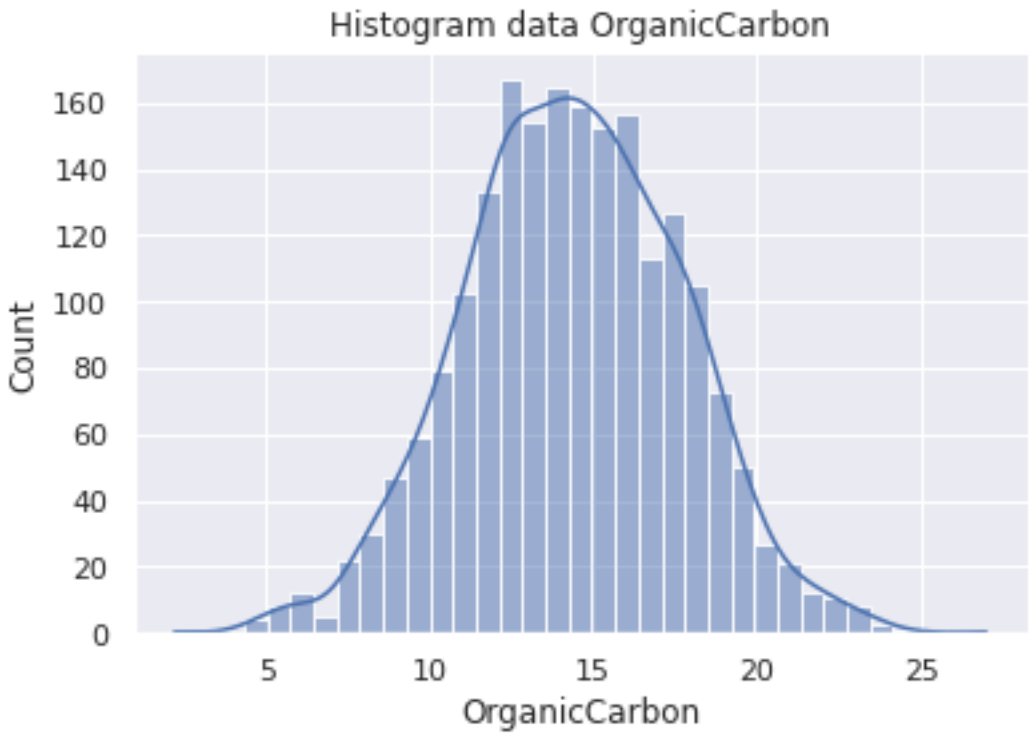

Dari kedua grafik diatas, data OrganicCarbon terlihat mendekati bentuk normal. Hal ini dapat terlihat bahwa pada QQ plot, sebagian besar titik berada pada garis. Oleh karena itu, dapat disimpulkan bahwa pH merupakan data yang berkemungkinan berdistribusi normal.

Pada bagian selanjutnya, data akan diuji menggunakan pendekatan statistik.

[ ]:
```
_, p = scipy.stats.normaltest(data["OrganicCarbon"])
print(f"p = {p}")

if p < alpha:
  print("Data tidak berdistribusi normal")
else:
  print("Data berdistribusi normal")
```

```
p = 0.8825496581408284
Data berdistribusi normal
```

Berdasarkan pengujian statistik, terlihat bahwa berdistribusi normal. Hal ini ditunjukan bahwa nilai $p > 0.05$. Oleh karena itu, hipotesis H_0 tidak dapat ditolak.

Kesimpulan dari pengujian ini adalah data OrganicCarbon merupakan data yang berdistribusi normal

1.5.9 Data Trihalomethanes

Pada bagian ini, akan dicoba untuk melakukan test normal pada data Trihalomethanes. Berikut ini adalah histogram dan juga QQ plot dari data Trihalomethanes.

[ ]:
```
QQ_Plot(data["Trihalomethanes"])
plt.title("QQ Plot pH")
```

[ ]:
```
Text(0.5, 1.0, 'QQ Plot pH')
```

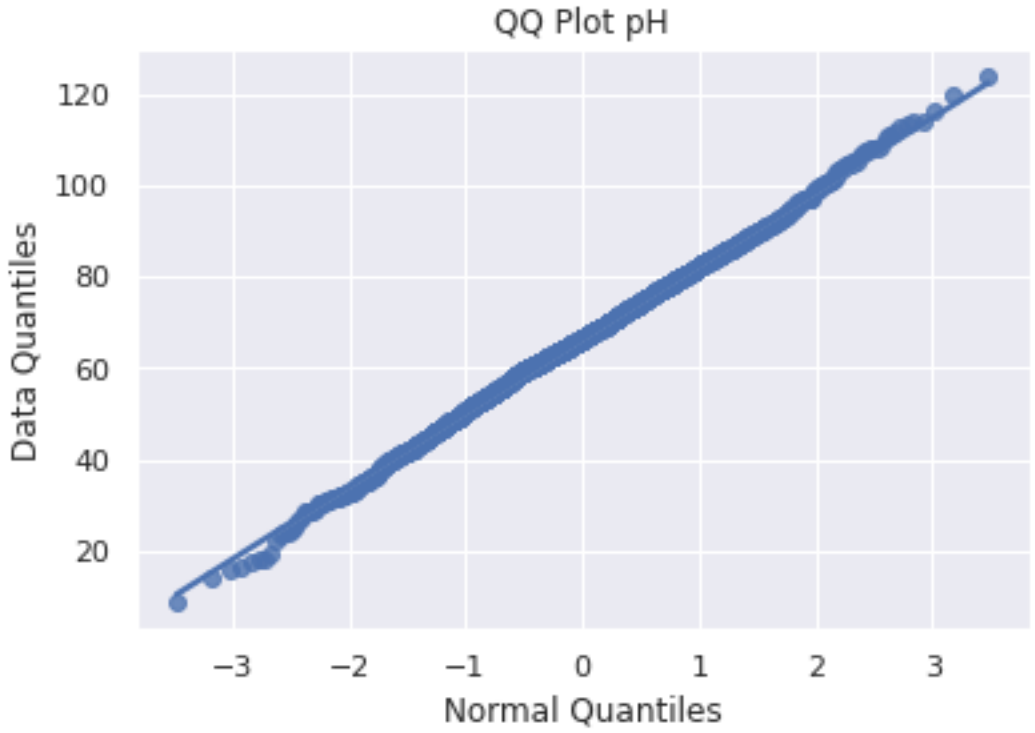

[ ]:
```
sns.histplot(data=data, x="Trihalomethanes", kde=True)
plt.title("Histogram data Trihalomethanes")
```

[ ]:
```
Text(0.5, 1.0, 'Histogram data Trihalomethanes')
```

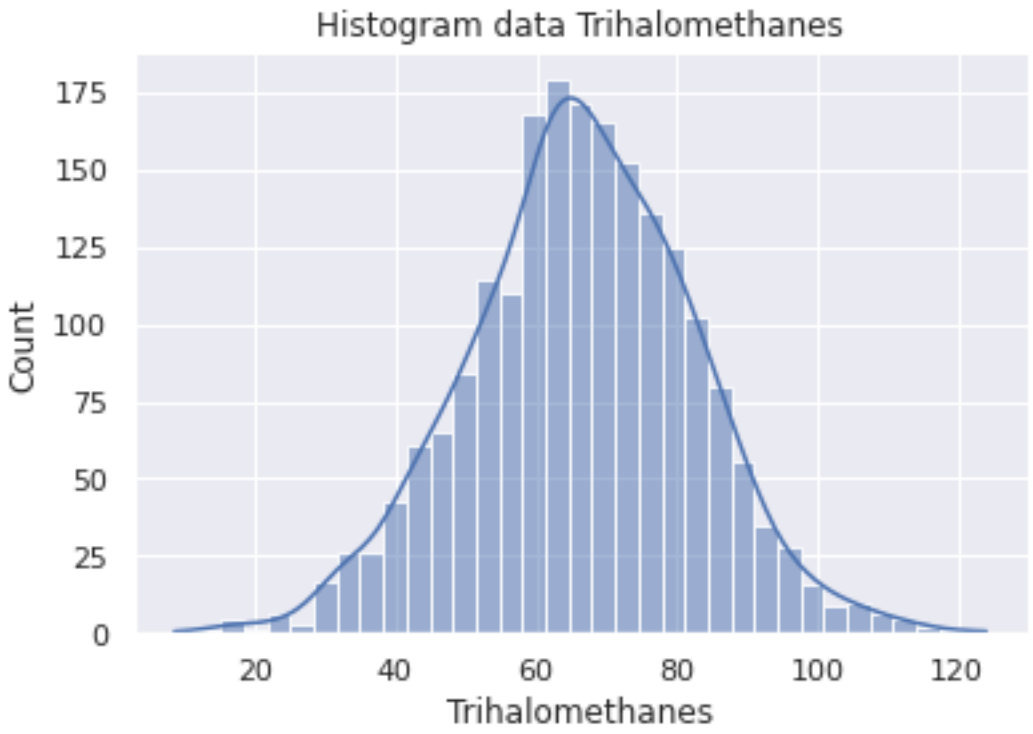

Dari kedua grafik diatas, data Trihalomethanes terlihat mendekati bentuk normal. Hal ini dapat terlihat bahwa pada QQ plot, sebagian besar titik berada pada garis. Oleh karena itu, dapat disimpulkan bahwa Trihalomethanes merupakan data yang berkemungkinan berdistribusi normal.

Pada bagian selanjutnya, data akan diuji menggunakan pendekatan statistik.

[ ]:
```
_, p = scipy.stats.normaltest(data["Trihalomethanes"])
print(f"p = {p}")

if p < alpha:
  print("Data tidak berdistribusi normal")
else:
  print("Data berdistribusi normal")
```

```
p = 0.1043598441875204
Data berdistribusi normal
```

Berdasarkan pengujian statistik, terlihat bahwa berdistribusi normal. Hal ini ditunjukan bahwa nilai $p > 0.05$. Oleh karena itu, hipotesis H_0 tidak dapat ditolak.

Kesimpulan dari pengujian ini adalah data Trihalomethanes merupakan data yang berdistribusi normal

1.5.10 Data Turbidity

Pada bagian ini, akan dicoba untuk melakukan test normal pada data Turbidity. Berikut ini adalah histogram dan juga QQ plot dari data Turbidity.

[ ]:
```
QQ_Plot(data["Turbidity"])
plt.title("QQ Plot Turbidity")
```

[ ]:
```
Text(0.5, 1.0, 'QQ Plot Turbidity')
```

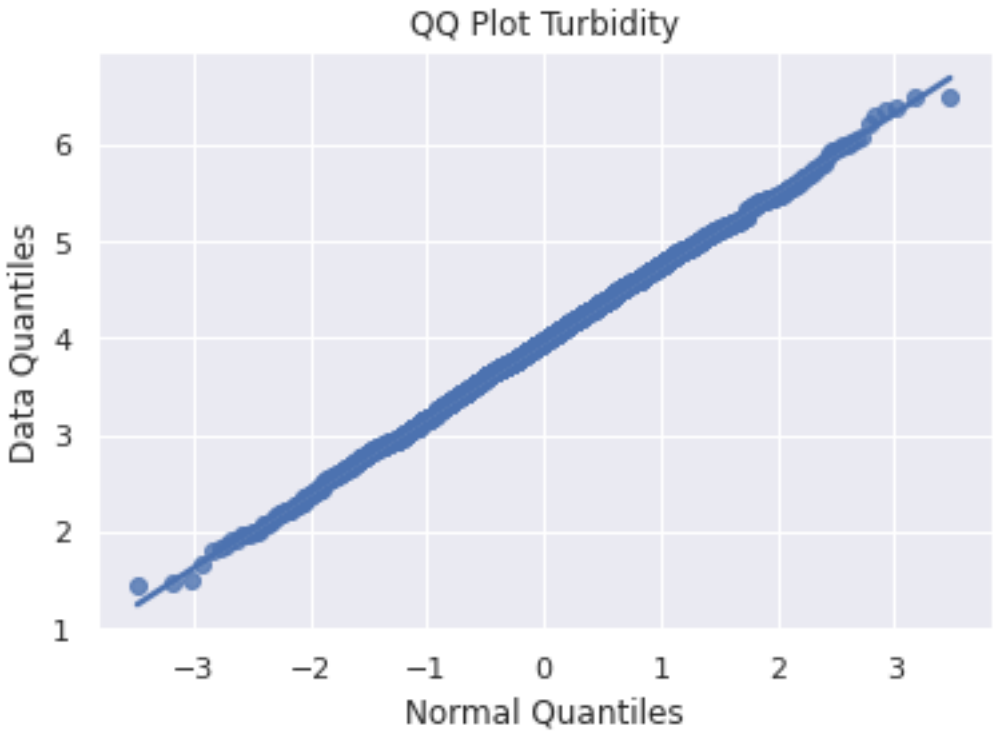

[ ]:
```
sns.histplot(data=data, x="Turbidity", kde=True)
plt.title("Histogram data Turbidity")
```

[ ]:
```
Text(0.5, 1.0, 'Histogram data Turbidity')
```

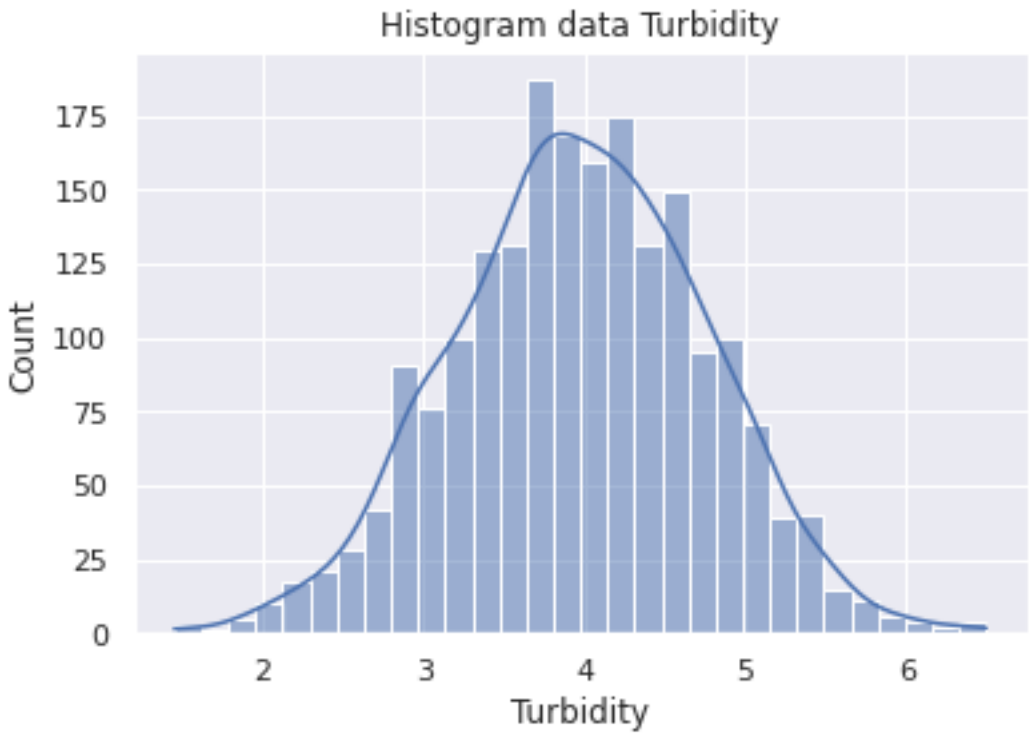

Dari kedua grafik diatas, data Turbidity terlihat mendekati bentuk normal. Hal ini dapat terlihat bahwa pada QQ plot, sebagian besar titik berada pada garis. Oleh karena itu, dapat disimpulkan bahwa Turbidity merupakan data yang berkemungkinan berdistribusi normal.

Pada bagian selanjutnya, data akan diuji menggunakan pendekatan statistik.

[ ]:
```
_, p = scipy.stats.normaltest(data["Turbidity"])
print(f"p = {p}")

if p < alpha:
  print("Data tidak berdistribusi normal")
else:
  print("Data berdistribusi normal")
```

```
p = 0.7694717369961169
Data berdistribusi normal
```

Berdasarkan pengujian statistik, terlihat bahwa berdistribusi normal. Hal ini ditunjukan bahwa nilai $p > 0.05$. Oleh karena itu, hipotesis H_0 tidak dapat ditolak.

Kesimpulan dari pengujian ini adalah data Turbidity merupakan data yang berdistribusi normal

1.6 Nomor 4: Uji Hipotesis 1 Sampel

Pada nomor ini, akan dilakukan uji sampel terhadap beberapa variabel.

1.6.1 Soal 4.a.

Akan diuji hipotesis apakah populasi memiliki nilai rata-rata pH diatas 7. Berikut ini adalah boxplot dari data pH.

[ ]:
```
sns.boxplot(data = data, x = "pH")
```

[ ]:
```
<AxesSubplot:xlabel='pH'>
```

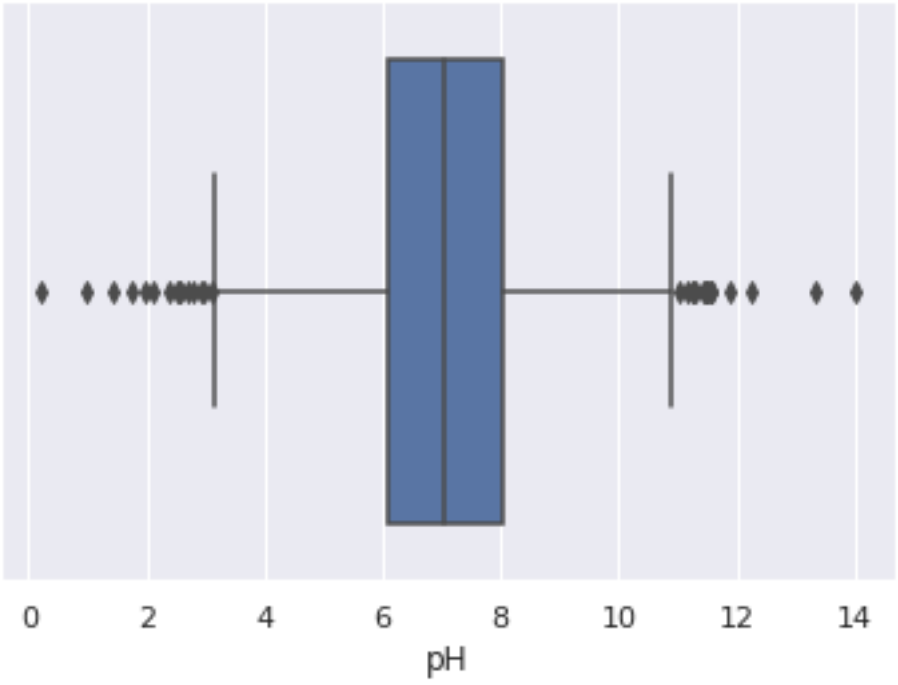

Langkah 1 : Penentuan Hipotesis Nol Pada soal ini, ditentukan bahwa hipotesis nol (H_0) adalah rata-rata pH populasi bernilai 7. Oleh karena itu, diambil

$$H_0 : \mu_{pH} = 7$$

Langkah 2: Penentuan Hipotesis Alternatif Diambil hipotesis alternatif dari permasalahan ini adalah rata-rata pH populasi bernilai lebih dari 7. Oleh karena itu, diambil

$$H_1 : \mu_{pH} > 7$$

Langkah 3: Penentuan Nilai Signifikansi dan Daerah kritis Diambil nilai signifikansi (α) bernilai 5%. Akan dihitung nilai daerah kritisnya. Dikarenakan dilakukan proses pengujian pada rata-rata, maka digunakanlah distibusi normal.

[ ]:
```
tValue = scipy.stats.t.ppf(1-0.05, data["pH"].size - 1)
tValue
```

[ ]:
```
1.6456124504017113
```

Oleh karena itu, daerah kritisnya adalah

$$t > 1.6456$$

Langkah 4: Pengujian Statistik Akan dilakukan pengujian statistik. Akan dihitung nilai berikut

$$t_0 = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$$

yang dalam hal ini, $\bar{X}$ menyatakan rata-rata sampel, μ_0 rata-rata yang sesuai dengan H_0, s adalah simpangan baku sampel, dan n adalah jumlah sampel.

[ ]:
```
t_0 = (np.mean(data["pH"]) - 7)/(np.std(data["pH"], ddof=1)/np.sqrt(data["pH"].
↪size))
t_0
```

[ ]:
```
2.485445147379887
```

Akan dihitung nilai p dari data yang diketahui diatas

[ ]:
```
p = 1-scipy.stats.t.cdf(t_0,  data["pH"].size - 1)
p
```

[ ]:
```
0.006509872359240942
```

Langkah 5: Pengambilan Keputusan Dikarenakan $p = 0.0065 < 0.05$ dan $t_0 > 1.6456$, maka hipotesisi H_0 tertolak. Oleh karena itu, nilai rata-rata pH lebih besar daripada 7.

1.6.2 Soal 4.b.

Akan diuji hipotesis apakah populasi memiliki nilai rata-rata Hardness tidak sama dengan 205. Berikut ini adalah boxplot dari data Hardness.

[ ]:
```
sns.boxplot(data = data, x = "Hardness")
```

[ ]:
```
<AxesSubplot:xlabel='Hardness'>
```

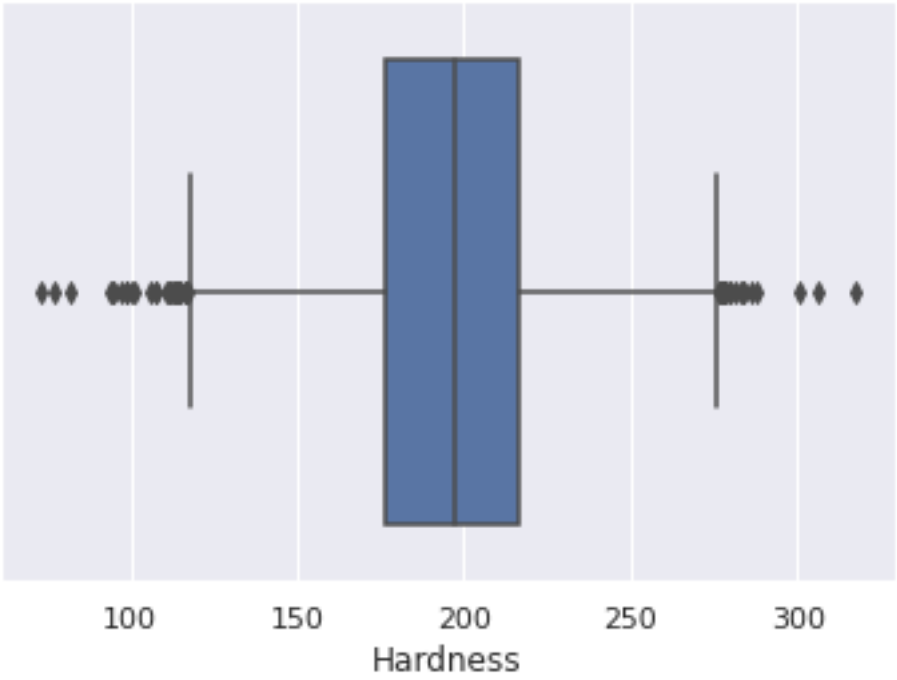

Langkah 1 : Penentuan Hipotesis Nol Pada soal ini, ditentukan bahwa hipotesis nol (H_0) adalah rata-rata Hardness populasi bernilai 205. Oleh karena itu, diambil

$$H_0 : \mu_{Hardness} = 205$$

Langkah 2: Penentuan Hipotesis Alternatif Diambil hipotesis alternatif dari permasalahan ini adalah rata-rata Hardness populasi bernilai tidak sama dengan 205. Oleh karena itu, diambil

$$H_1 : \mu_{Hardness} \neq 205$$

Langkah 3: Penentuan Nilai Signifikansi dan Daerah kritis Diambil nilai signifikansi (α) bernilai 5%. Akan dihitung nilai daerah kritisnya. Dikarenakan dilakukan proses pengujian pada rata-rata, maka digunakanlah distibusi normal.

[ ]:
```
t = scipy.stats.t
criticalVal = t.ppf(0.05/2, data["Hardness"].size - 1)
criticalVal
```

[ ]:
```
-1.9611455060885266
```

Oleh karena itu, daerah kritisnya adalah

$$t > 1.961 \vee t < -1.961$$

Langkah 4: Pengujian Statistik Akan dilakukan pengujian statistik. Akan dihitung nilai berikut

$$t_0 = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$$

yang dalam hal ini, $\bar{X}$ menyatakan rata-rata sampel, μ_0 rata-rata yang sesuai dengan H_0, s adalah simpangan baku sampel, dan n adalah jumlah sampel.

[ ]:
```
t_0 = (np.mean(data["Hardness"]) - 205)/(np.std(data["Hardness"], ddof=1)/np.
↪sqrt(data["Hardness"].size))
t_0
```

[ ]:
```
-12.403137170010732
```

Akan dihitung nilai p dari data yang diketahui diatas

[ ]:
```
p = t.cdf(t_0, data["Hardness"].size - 1)
p
```

[ ]:
```
2.149590521597912e-34
```

Langkah 5: Pengambilan Keputusan Dikarenakan $p < 0.05$ dan $t_0 < -1.961$, maka hipotesis H_0 tertolak. Oleh karena itu, nilai rata-rata hardness tidak sama dengan 205.

1.6.3 Soal 4.c.

Akan diuji hipotesis apakah rata-rata populasi dengan sampel 100 baris pertama kolom Solid bukan 21900. Berikut ini adalah boxplot dari 100 baris pertama kolom Solids.

[ ]:
```
sns.boxplot(data = data[:100], x = "Solids")
```

[ ]:
```
<AxesSubplot:xlabel='Solids'>
```

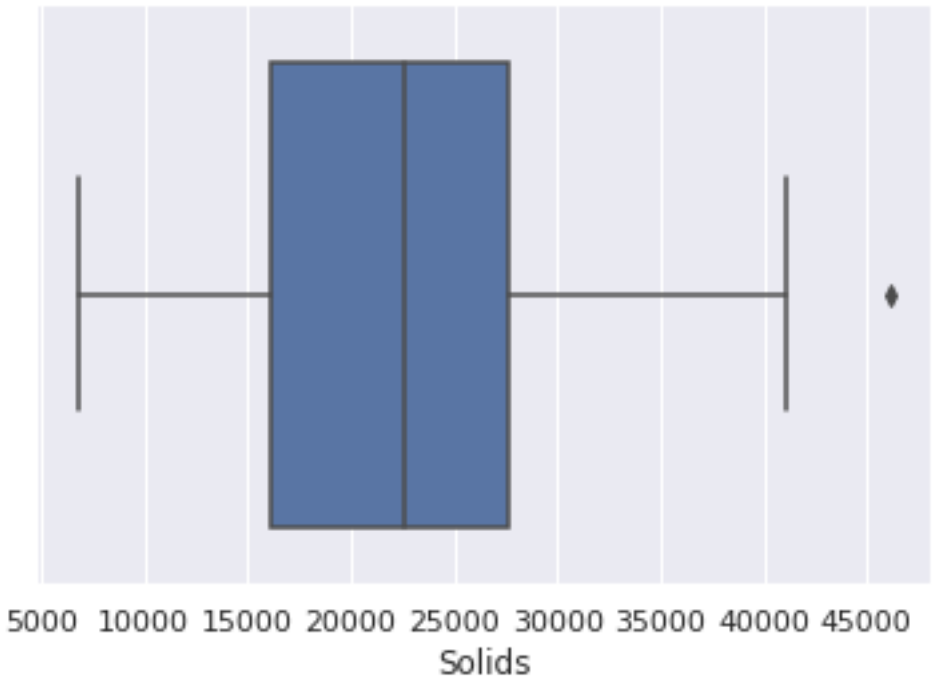

Berikut ini adalah pengambilan 100 data pertama.

[ ]:
```
solid100 = data["Solids"].iloc[:100]
solid100.info()
```

```
<class 'pandas.core.series.Series'>
RangeIndex: 100 entries, 0 to 99
Series name: Solids
Non-Null Count  Dtype
--------------  -----
100 non-null    float64
dtypes: float64(1)
memory usage: 928.0 bytes
```

[ ]:
```
solid100.head()
```

[ ]:
```
0    22018.417441
1    17978.986339
2    28748.687739
3    28749.716544
4    13672.091764
Name: Solids, dtype: float64
```

Langkah 1 : Penentuan Hipotesis Nol Pada soal ini, ditentukan bahwa hipotesis nol (H_0) adalah rata-rata Hardness populasi bernilai 205. Oleh karena itu, diambil

$$H_0 : \mu_{solid} = 21900$$

Langkah 2: Penentuan Hipotesis Alternatif Diambil hipotesis alternatif dari permasalahan ini adalah rata-rata Hardness populasi bernilai tidak sama dengan 205. Oleh karena itu, diambil

$$H_1 : \mu_{Hardness} \neq 21900$$

Langkah 3: Penentuan Nilai Signifikansi dan Daerah kritis Diambil nilai signifikansi (α) bernilai 5%. Akan dihitung nilai daerah kritisnya. Dikarenakan dilakukan proses pengujian pada rata-rata, maka digunakanlah distibusi normal.

[ ]:
```
t = scipy.stats.t
criticalVal = t.ppf(1-0.05/2, solid100.size - 1)
criticalVal
```

[ ]:
```
1.9842169515086827
```

Oleh karena itu, daerah kritisnya adalah

$$t > 1.984 \vee t < -1.984$$

Langkah 4: Pengujian Statistik Akan dilakukan pengujian statistik. Akan dihitung nilai berikut

$$t_0 = \frac{\bar{X} - \mu_0}{s/\sqrt{n}}$$

yang dalam hal ini, $\bar{X}$ menyatakan rata-rata sampel, μ_0 rata-rata yang sesuai dengan H_0, s adalah simpangan baku sampel, dan n adalah jumlah sampel.

[ ]:
```
t_0 = (np.mean(solid100) - 21900)/(np.std(solid100, ddof=1)/np.sqrt(solid100.
↪size))
t_0
```

[ ]:
```
0.5636797715721551
```

Akan dihitung nilai p dari data yang diketahui diatas

[ ]:
```
p = 1-t.cdf(t_0, solid100.size - 1)
p
```

[ ]:
```
0.2871233567026301
```

Langkah 5: Pengambilan Keputusan Dikarenakan $p > 0.05$ dan $t_0 < 1.98$, maka hipotesisi H_0 diterima. Oleh karena itu, nilai rata-rata populasi dari sambel 100 kolom solids adalah 21900.

1.6.4 Soal 4.d.

Akan diuji proporsi nilai Conductivity yang lebih dari 450 adalah tidak sama dengan 10%. Berikut ini adalah boxplot dari data Conductivity.

[ ]:
```
sns.boxplot(data = data, x = "Conductivity")
```

[ ]:
```
<AxesSubplot:xlabel='Conductivity'>
```

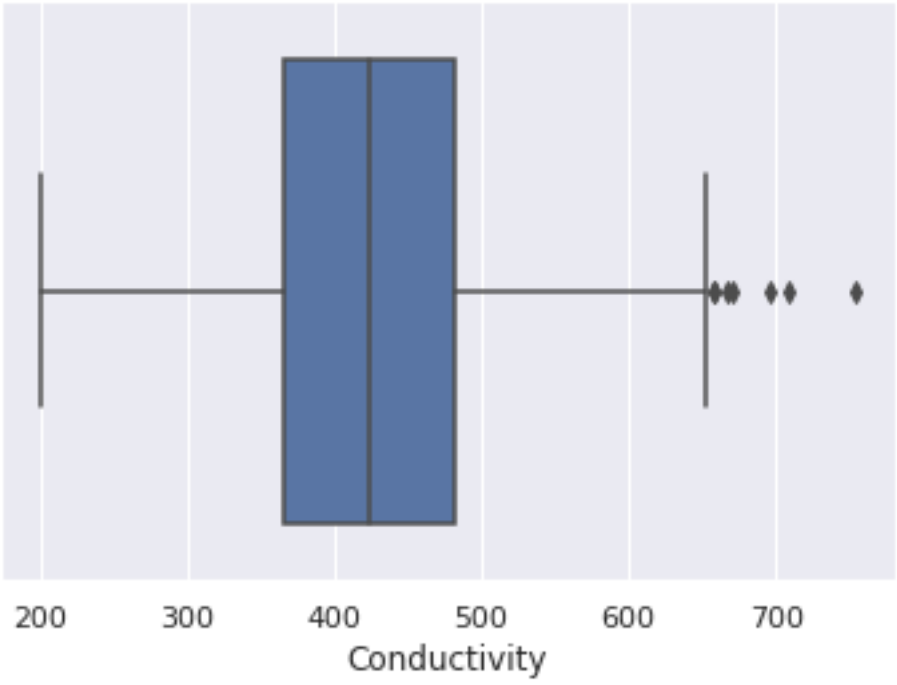

Langkah 1 : Penentuan Hipotesis Nol Pada soal ini, ditentukan bahwa hipotesis nol (H_0) adalah proporsi nilai Conductivity yang lebih dari 450 sama dengan 10%. Oleh karena itu, diambil

$$H_0 : p_{Conductivity} = 10\%$$

Langkah 2: Penentuan Hipotesis Alternatif Diambil hipotesis alternatif dari permasalahan ini adalah proporsi nilai Conductivity yang lebih dari 450 tidak sama dengan 10%

$$H_1 : p_{Conductivity} \neq 10\%$$

Langkah 3: Penentuan Nilai Signifikansi dan Daerah kritis Diambil nilai signifikansi (α) bernilai 5%. Akan dihitung nilai daerah kritisnya. Dikarenakan dilakukan proses pengujian pada rata-rata, maka digunakanlah distribusi normal.

[ ]:
```
norm = scipy.stats.norm()
criticalVal = norm.ppf(1-0.05/2)
```

```
criticalVal
```

[ ]:
```
1.959963984540054
```

Oleh karena itu, daerah kritisnya adalah

$$z < -1.960 \vee z > 1.960$$

Langkah 4: Pengujian Statistik Akan dilakukan pengujian statistik. Perhitungan proporsi akan dilakukan dengan menggunakan pendekatan distribusi normal. Akan dicari simpangan baku dan rata-rata dari distribusi binomial.

Rumus untuk mencari nilai rata-rata dan simpangan baku dari distribusi binomial adalah sebagai berikut:

$$\mu = np$$

$$\sigma = \sqrt{npq}$$

Selanjutnya akan dicari nilai rata-rata dan simpangan baku yang dibutuhkan dalam perhitungan.

[ ]:
```
mu = data["Conductivity"].shape[0] * 0.1
sigma = np.sqrt(data["Conductivity"].shape[0]*0.1*0.9)
print(f"Nilai rata-rata = {mu}")
print(f"Nilai simpangan baku = {sigma}")
```

```
Nilai rata-rata = 201.0
Nilai simpangan baku = 13.449907062875937
```

Selanjutnya dihitung jumlah data Conductivity yang lebih dari 450.

[ ]:
```
cdv_gt_450 = data[data["Conductivity"] > 450]["Conductivity"].size
print(f"Jumlah data Conductivity yang bernilai lebih dari 450: {cdv_gt_450}")
```

```
Jumlah data Conductivity yang bernilai lebih dari 450: 745
```

Berikutnya akan dihitung nilai z untuk mencari distribusi normal pada data Conductivity tersebut. Rumus untuk mencari z tersebut adalah sebagai berikut:

$$z = \frac{X - \mu}{\sigma}$$

Di dalam hal ini, X adalah banyaknya data Conductivity yang bernilai lebih dari 450.

[ ]:
```
z = (cdv_gt_450 - mu)/sigma
z
```

[ ]:
```
40.446376131589325
```

Akan dicari nilai p untuk kasus ini.

```
[ ]: p = (1 - norm.cdf(z)) * 2
     p

[ ]: 0.0
```

Langkah 5: Pengambilan Keputusan Dikarenakan $p < 0.05$ dan $z_0 > 1.960$, maka hipotesis H_0 ditolak. Oleh karena itu, nilai proporsi Conductivity yang lebih dari 450 tidak sama dengan 10%.

1.6.5 Soal 4.e.

Akan diuji proporsi nilai Trihalomethanes yang kurang dari 40 adalah kurang dari 5%. Berikut ini adalah boxplot dari data Trihalomethanes.

```
[ ]: sns.boxplot(data = data, x = "Trihalomethanes")

[ ]: <AxesSubplot:xlabel='Trihalomethanes'>
```

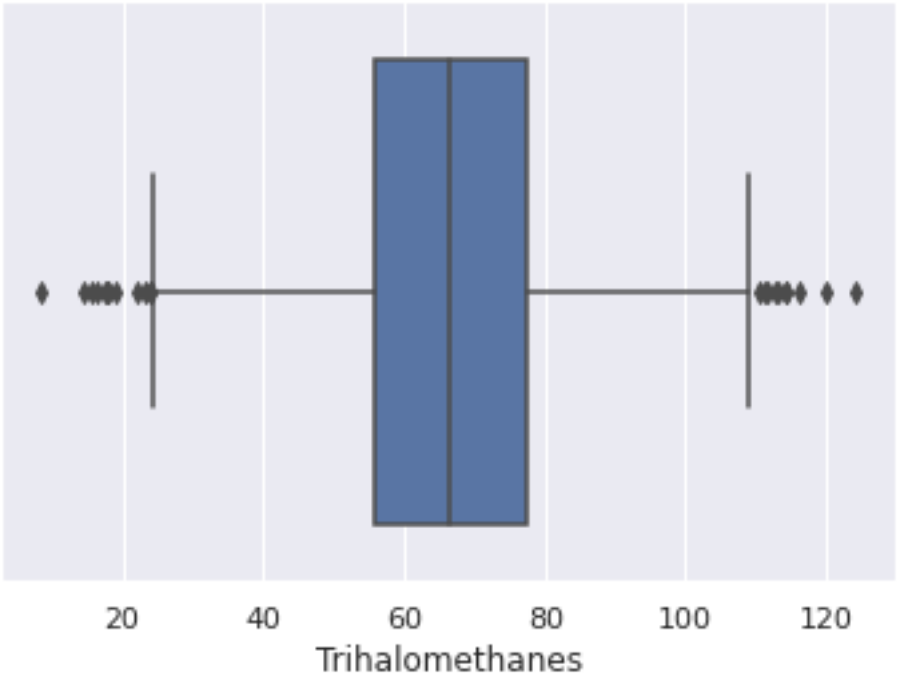

Langkah 1 : Penentuan Hipotesis Nol Pada soal ini, ditentukan bahwa hipotesis nol (H_0) adalah proporsi nilai Trihalomethanes yang kurang dari 40 sama dengan 5%. Oleh karena itu, diambil

$$H_0 : p_{Trihalomethanes} = 5\%$$

Langkah 2: Penentuan Hipotesis Alternatif Diambil hipotesis alternatif dari permasalahan ini adalah proporsi nilai Trihalomethanes yang kurang dari 40 kurang dari 5%

$$H_1 : p_{Trihalomethanes} < 5\%$$

Langkah 3: Penentuan Nilai Signifikansi dan Daerah kritis Diambil nilai signifikansi (α) bernilai 5%. Akan dihitung nilai daerah kritisnya. Dikarenakan dilakukan proses pengujian pada rata-rata, maka digunakanlah distribusi normal.

[ ]:
```
norm = scipy.stats.norm()
criticalVal = norm.ppf(0.05)
criticalVal
```

[ ]:
```
-1.6448536269514729
```

Oleh karena itu, daerah kritisnya adalah

$$z < -1.645$$

Langkah 4: Pengujian Statistik Akan dilakukan pengujian statistik. Perhitungan proporsi akan dilakukan dengan menggunakan pendekatan distribusi normal. Akan dicari simpangan baku dan rata-rata dari distribusi binomial.

Rumus untuk mencari nilai rata-rata dan simpangan baku dari distribusi binomial adalah sebagai berikut:

$$\mu = np$$

$$\sigma = \sqrt{npq}$$

Selanjutnya akan dicari nilai rata-rata dan simpangan baku yang dibutuhkan dalam perhitungan.

[ ]:
```
mu = data["Trihalomethanes"].shape[0] * 0.05
sigma = np.sqrt(data["Trihalomethanes"].shape[0]*0.05*0.95)
print(f"Nilai rata-rata = {mu}")
print(f"Nilai simpangan baku = {sigma}")
```

```
Nilai rata-rata = 100.5
Nilai simpangan baku = 9.771130947848361
```

Selanjutnya dihitung jumlah data Trihalomethanes yang kurang dari 40.

[ ]:
```
trh_lt_40 = data[data["Trihalomethanes"] < 40]["Trihalomethanes"].size
print(f"Jumlah data Trihalomethanes yang bernilai kurang dari 40: {trh_lt_40}")
```

```
Jumlah data Trihalomethanes yang bernilai kurang dari 40: 106
```

Berikutnya akan dihitung nilai z untuk mencari distribusi normal pada data Trihalomethanes tersebut. Rumus untuk mencari z tersebut adalah sebagai berikut:

$$z = \frac{X - \mu}{\sigma}$$

Di dalam hal ini, X adalah banyaknya data Trihalomethanes yang bernilai kurang dari 40.

[ ]:
```
z = (trh_lt_40 - mu)/sigma
z
```

[ ]:
```
0.5628826416670959
```

Akan dicari nilai p untuk kasus ini.

[ ]:
```
p = norm.cdf(z)
p
```

[ ]:
```
0.7132425995092373
```

Langkah 5: Pengambilan Keputusan Dikarenakan $p > 0.05$ dan $z_0 > -1.645$, maka hipotesis H_0 diterima. Oleh karena itu, nilai proporsi Trihalomethanes yang kurang dari 40 sama dengan 5%.

1.7 Nomor 5: Uji Hipotesis 2 Sampel

Pada soal ini, kami akan menguji beberapa hipotesis yang melibatkan dua dataset.

1.7.1 Soal 5.a.

Pada soal ini, akan diuji apakah rata-rata bagian awal dan bagian akhir kolom sulfate apabila dibagi menjadi 2 sama rata memiliki rata-rata yang sama. Sebelum itu kami membagi dataset Sulfate menjadi dua bagian sama besar, yaitu sebagai berikut.

[ ]:
```
SulfateAwal = data["Sulfate"].iloc[:data["Sulfate"].size//2]
SulfateAkhir = data["Sulfate"].iloc[data["Sulfate"].size//2:]
SulfateAwal.info()
SulfateAkhir.info()
```

```
<class 'pandas.core.series.Series'>
RangeIndex: 1005 entries, 0 to 1004
Series name: Sulfate
Non-Null Count  Dtype
--------------  -----
1005 non-null   float64
dtypes: float64(1)
memory usage: 8.0 KB
<class 'pandas.core.series.Series'>
RangeIndex: 1005 entries, 1005 to 2009
Series name: Sulfate
Non-Null Count  Dtype
```

```
--------------  -----
1005 non-null   float64
dtypes: float64(1)
memory usage: 8.0 KB
```

Berikut ini adalah boxplot dari kedua data Sulfate tersebut.

[ ]:
```
sns.boxplot(x = SulfateAwal)
```

[ ]:
```
<AxesSubplot:xlabel='Sulfate'>
```

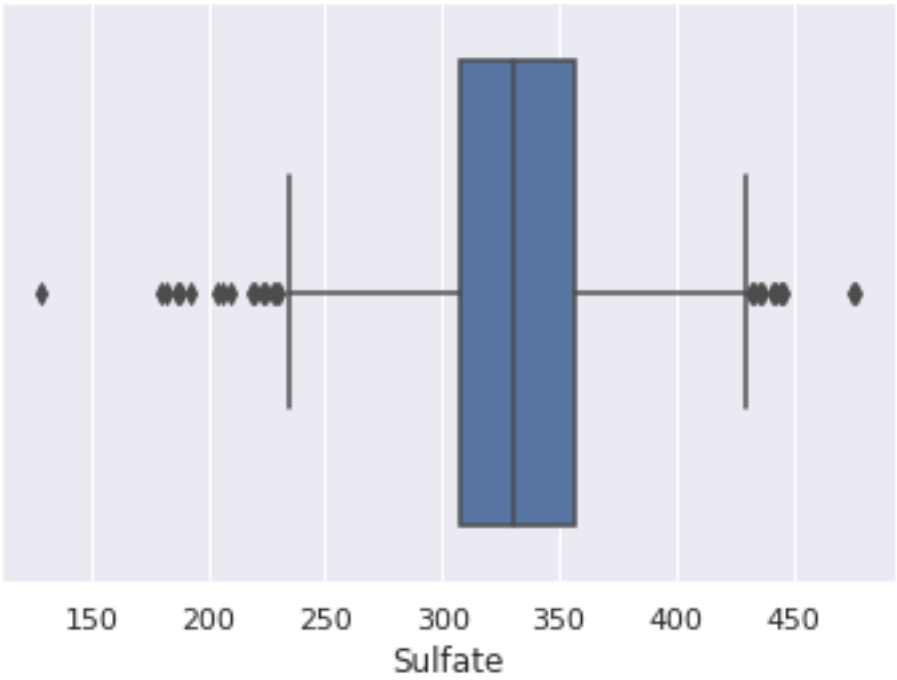

[ ]:
```
sns.boxplot(x = SulfateAkhir)
```

[ ]:
```
<AxesSubplot:xlabel='Sulfate'>
```

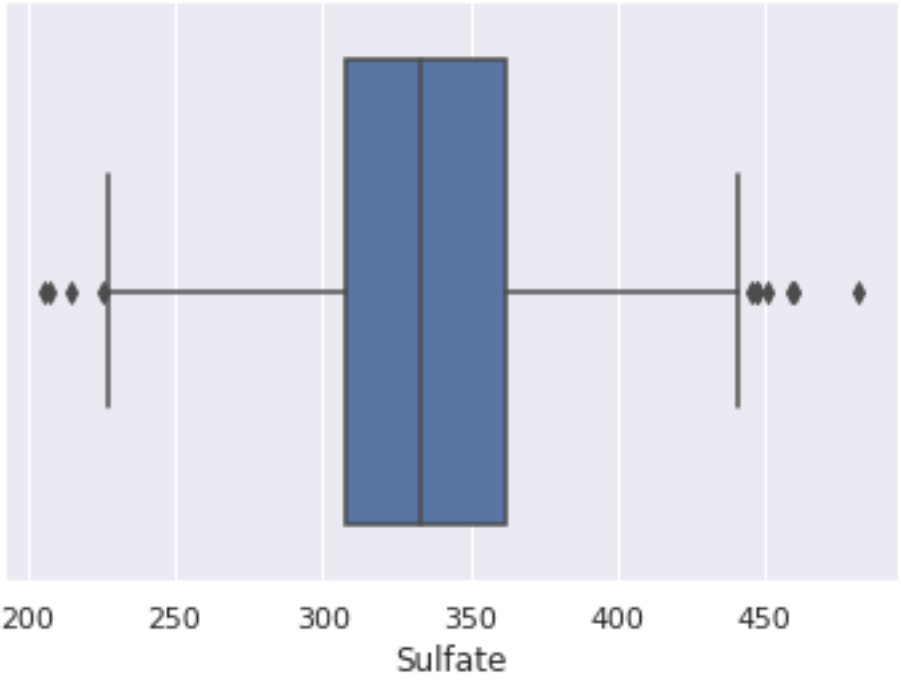

Selanjutnya, akan diuji apakah kedua data Sulfate tersebut memiliki rata-rata yang sama.

Langkah 1 : Penentuan Hipotesis Nol Pada soal ini, ditentukan bahwa hipotesis nol (H_0) adalah rata-rata Sulfate awal dan Sulfate akhir adalah sama. Oleh karena itu, diambil

$$H_0 : \mu_{SulfateAwal} - \mu_{SulfateAkhir} = 0$$

Langkah 2: Penentuan Hipotesis Alternatif Diambil hipotesis alternatif dari permasalahan ini adalah rata-rata Sulfate awal dan Sulfate akhir berbeda. Oleh karena itu diambil

$$H_1 : \mu_{SulfateAwal} - \mu_{SulfateAkhir} \neq 0$$

Langkah 3: Penentuan Nilai Signifikansi dan Daerah kritis Diambil nilai signifikansi (α) bernilai 5%. Akan dihitung nilai daerah kritisnya. Dikarenakan dilakukan proses pengujian pada rata-rata, maka digunakanlah distribusi t.

Sebelumnya, akan dihitung terlebih dahulu nilai derajat kebebasan dari dua buah sampel. Berikut ini adalah rumus untuk menghitung derajat kebebasan.

$$v = n_1 + n_2 - 2$$

Berikut ini adalah perhitungannya menggunakan python

[ ]:
```
v_sulfate = SulfateAwal.count() + SulfateAkhir.count() - 2
v_sulfate
```

[ ]:
```
2008
```

Selanjutnya akan dihitung nilai titik kritisnya untuk mencari daerah kritisnya.

[ ]:
```
tValue = scipy.stats.t.ppf(0.05/2, v_sulfate)
tValue
```

[ ]:
```
-1.961146094844425
```

Oleh karena itu, daerah kritisnya adalah

$$t < -1.961 \vee t > 1.961$$

Langkah 4: Pengujian Statistik Akan dilakukan pengujian statistik. Akan dihitung nilai berikut

$$t_0 = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{s_p\sqrt{1/n_1 + 1/n_2}}$$

yang dalam hal ini, $\bar{x}_1$ menyatakan rata-rata sampel dari dataset pertama (SulfateAwal) dan $\bar{x}_2$ menyatakan rata-rata dari dataset kedua (SulfateAkhir) dan s_p menyatakan simpangan baku gabungan dari kedua sampel. Nilai s_p dapat dihitung dengan rumus berikut.

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

Berikut ini adalah perhitungan nilai s_p

[ ]:
```
n1 = SulfateAwal.count()
n2 = SulfateAkhir.count()
s1_sqr = SulfateAwal.var(ddof=1)
s2_sqr = SulfateAkhir.var(ddof=1)
```

[ ]:
```
sp_sqr = (((n1-1)*s1_sqr)+((n2-1)*s2_sqr))/(n1+n2-2)
sp = np.sqrt(sp_sqr)
sp
```

[ ]:
```
41.1772368337153
```

Selanjutnya akan dihitung nilai t_0

[ ]:
```
x1_bar = np.mean(SulfateAwal)
x2_bar = np.mean(SulfateAkhir)
```

[ ]:
```
t0 = (x1_bar - x2_bar - 0)/(sp*np.sqrt(1/n1+1/n2))
t0
```

[ ]:
```
-2.0752690696871983
```

Akan dihitung nilai p dari data yang diketahui diatas

[ ]:
```
p = scipy.stats.t.cdf(t0,  v_sulfate) * 2
p
```

[ ]:
```
0.03808865190737513
```

Langkah 5: Pengambilan Keputusan Dikarenakan $p = 0.038 < 0.05$ dan $t_0 = -2.075 < -1.961$, maka hipotesis H_0 tertolak. Oleh karena itu, nilai rata-rata kedua dataset tersebut berbeda.

1.7.2 Soal 5.b.

Pada soal ini, akan diuji apakah rata-rata bagian awal dan bagian akhir kolom OrganicCarbon apabila dibagi menjadi 2 sama rata memiliki rata-rata bagian awal yang lebih besar dari pada bagian akhir sebesar 0.15. Sebelum itu kami membagi dataset OrganicCarbon menjadi dua bagian sama besar, yaitu sebagai berikut.

[ ]:
```
OrganicCarbonAwal = data["OrganicCarbon"].iloc[:data["OrganicCarbon"].size//2]
OrganicCarbonAkhir = data["OrganicCarbon"].iloc[data["OrganicCarbon"].size//2:]
OrganicCarbonAwal.info()
OrganicCarbonAkhir.info()
```

```
<class 'pandas.core.series.Series'>
RangeIndex: 1005 entries, 0 to 1004
Series name: OrganicCarbon
Non-Null Count  Dtype
--------------  -----
1005 non-null   float64
dtypes: float64(1)
memory usage: 8.0 KB
<class 'pandas.core.series.Series'>
RangeIndex: 1005 entries, 1005 to 2009
Series name: OrganicCarbon
Non-Null Count  Dtype
--------------  -----
1005 non-null   float64
dtypes: float64(1)
memory usage: 8.0 KB
```

Berikut ini adalah boxplot dari kedua data OrganicCarbon tersebut.

[ ]:
```
sns.boxplot(x = OrganicCarbonAwal)
```

[ ]:
```
<AxesSubplot:xlabel='OrganicCarbon'>
```

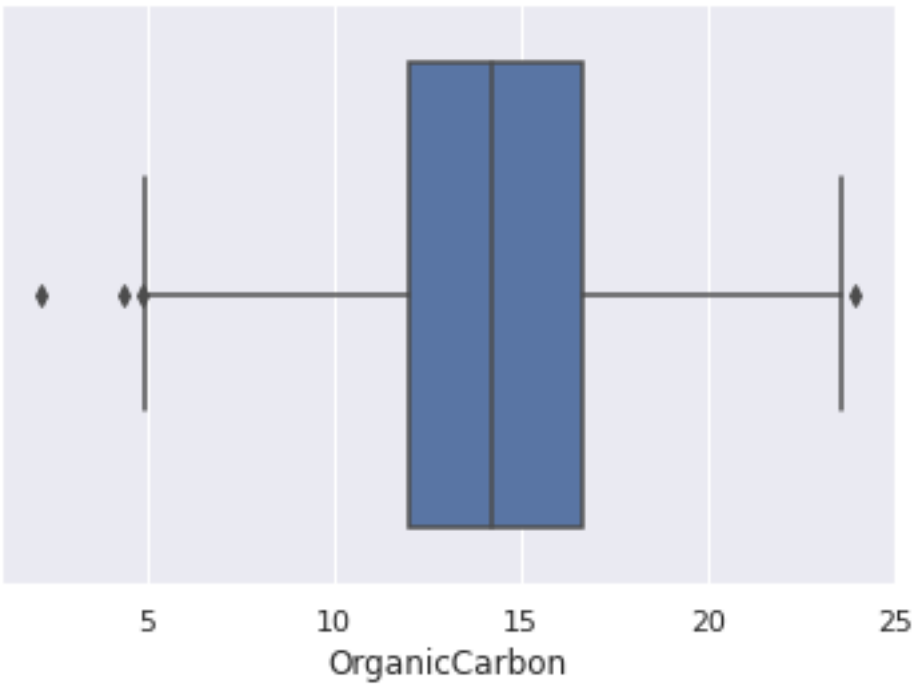

[ ]:
```
sns.boxplot(x = OrganicCarbonAkhir)
```

[ ]:
```
<AxesSubplot:xlabel='OrganicCarbon'>
```

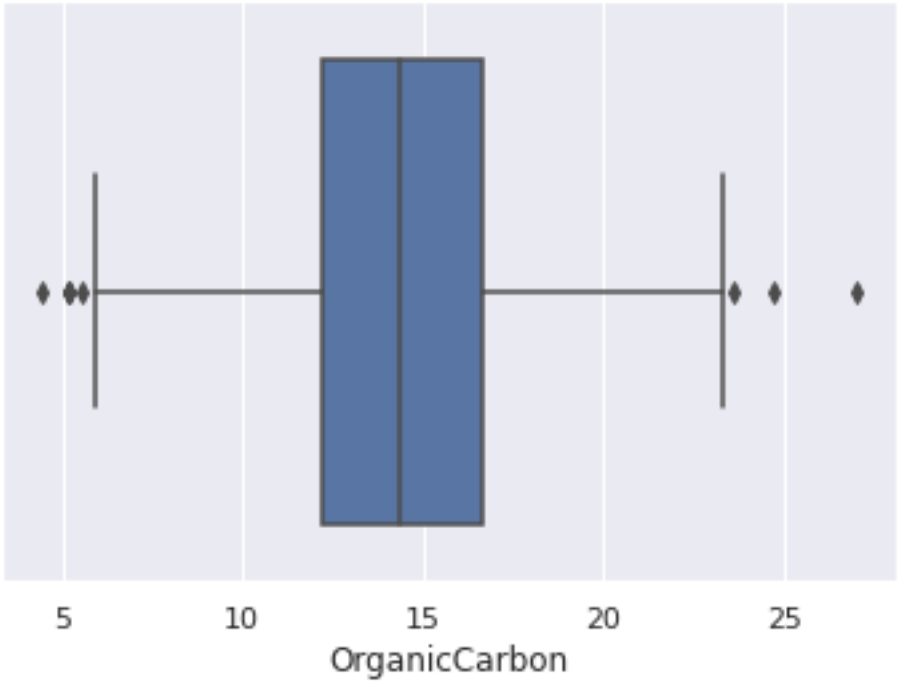

Selanjutnya, akan diuji apakah kedua data OrganicCarbon tersebut memiliki beda antara bagian awal dan bagian akhir sama dengan 0.15

Langkah 1 : Penentuan Hipotesis Nol Pada soal ini, ditentukan bahwa hipotesis nol (H_0) adalah rata-rata OrganicCarbon awal dan OrganicCarbon akhir adalah lebih besar OrganicCarbon awal sebesar 0.15. Oleh karena itu, diambil

$$H_0 : \mu_{OrganicCarbonAwal} - \mu_{OrganicCarbonAkhir} = 0.15$$

Langkah 2: Penentuan Hipotesis Alternatif Diambil hipotesis alternatif dari permasalahan ini adalah beda rata-rata OrganicCarbon awal dan OrganicCarbon akhir tidak sama dengan 0.15. Oleh karena itu diambil

$$H_1 : \mu_{OrganicCarbonAwal} - \mu_{OrganicCarbonAkhir} \neq 0.15$$

Langkah 3: Penentuan Nilai Signifikansi dan Daerah kritis Diambil nilai signifikansi (α) bernilai 5%. Akan dihitung nilai daerah kritisnya. Dikarenakan dilakukan proses pengujian pada rata-rata, maka digunakanlah distribusi t.

Sebelumnya, akan dihitung terlebih dahulu nilai derajat kebebasan dari dua buah sampel. Berikut ini adalah rumus untuk menghitung derajat kebebasan.

$$v = n_1 + n_2 - 2$$

Berikut ini adalah perhitungannya menggunakan python

[ ]:
```
v_OrganicCarbon = OrganicCarbonAwal.count() + OrganicCarbonAkhir.count() - 2
v_OrganicCarbon
```

[ ]:
```
2008
```

Selanjutnya akan dihitung nilai titik kritisnya untuk mencari daerah kritisnya.

[ ]:
```
tValue = scipy.stats.t.ppf(0.05/2, v_OrganicCarbon)
tValue
```

[ ]:
```
-1.961146094844425
```

Oleh karena itu, daerah kritisnya adalah

$$t < -1.961 \vee t > 1.961$$

Langkah 4: Pengujian Statistik Akan dilakukan pengujian statistik. Akan dihitung nilai berikut

$$t_0 = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{s_p\sqrt{1/n_1 + 1/n_2}}$$

yang dalam hal ini, $\bar{x}_1$ menyatakan rata-rata sampel dari dataset pertama (OrganicCarbonAwal) dan $\bar{x}_2$ menyatakan rata-rata dari dataset kedua (OrganicCarbonAkhir) dan s_p menyatakan simpangan baku gabungan dari kedua sampel. Nilai s_p dapat dihitung dengan rumus berikut.

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

Berikut ini adalah perhitungan nilai s_p

[ ]:
```
n1 = OrganicCarbonAwal.count()
n2 = OrganicCarbonAkhir.count()
s1_sqr = OrganicCarbonAwal.var(ddof=1)
s2_sqr = OrganicCarbonAkhir.var(ddof=1)
```

[ ]:
```
sp_sqr = (((n1-1)*s1_sqr)+((n2-1)*s2_sqr))/(n1+n2-2)
sp = np.sqrt(sp_sqr)
sp
```

[ ]:
```
3.324971353803503
```

Selanjutnya akan dihitung nilai t_0

[ ]:
```
x1_bar = np.mean(OrganicCarbonAwal)
x2_bar = np.mean(OrganicCarbonAkhir)
```

[ ]:
```
t0 = (x1_bar - x2_bar - 0.15)/(sp*np.sqrt(1/n1+1/n2))
t0
```

[ ]:
```
-2.413145517798807
```

Akan dihitung nilai p dari data yang diketahui diatas

[ ]:
```
p = scipy.stats.t.cdf(t0,  v_OrganicCarbon) * 2
p
```

[ ]:
```
0.01590454911867324
```

Langkah 5: Pengambilan Keputusan Dikarenakan $p = 0.016 < 0.05$ dan $t_0 = -2.413 < -1.961$, maka hipotesis H_0 ditolak. Oleh karena itu, nilai rata-rata bagian awal dan bagian akhir kolom OrganicCarbon memiliki beda yang tidak sama dengan 0.15

1.7.3 Soal 5.c.

Pada soal ini, akan diuji apakah rata-rata 100 data bagian awal dan 100 data bagian akhir kolom Chloramines memiliki rata-rata yang sama. Sebelum itu kami membagi dataset Chloramines menjadi dua bagian, yaitu sebagai berikut.

[ ]:
```
ChloraminesAwal = data["Chloramines"].iloc[:100]
ChloraminesAkhir = data["Chloramines"].iloc[-100:]
ChloraminesAwal.info()
ChloraminesAkhir.info()
```

```
<class 'pandas.core.series.Series'>
RangeIndex: 100 entries, 0 to 99
Series name: Chloramines
Non-Null Count  Dtype
--------------  -----
100 non-null    float64
dtypes: float64(1)
memory usage: 928.0 bytes
<class 'pandas.core.series.Series'>
RangeIndex: 100 entries, 1910 to 2009
Series name: Chloramines
Non-Null Count  Dtype
--------------  -----
100 non-null    float64
dtypes: float64(1)
memory usage: 932.0 bytes
```

Berikut ini adalah boxplot dari kedua data Chloramines tersebut.

[ ]:
```
sns.boxplot(x = ChloraminesAwal)
```

[ ]:
```
<AxesSubplot:xlabel='Chloramines'>
```

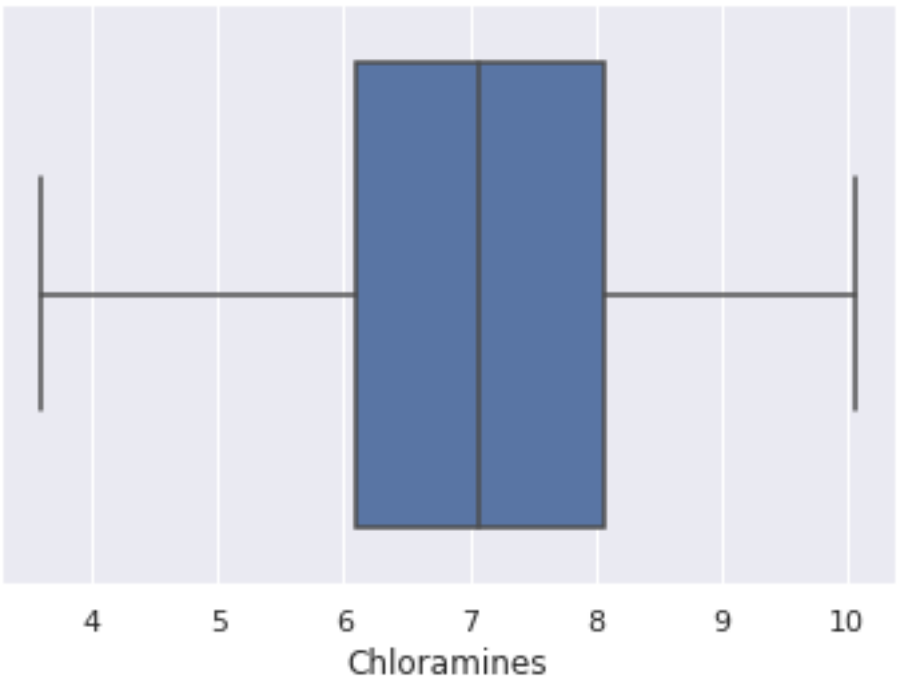

[ ]:
```
sns.boxplot(x = ChloraminesAkhir)
```

[ ]:
```
<AxesSubplot:xlabel='Chloramines'>
```

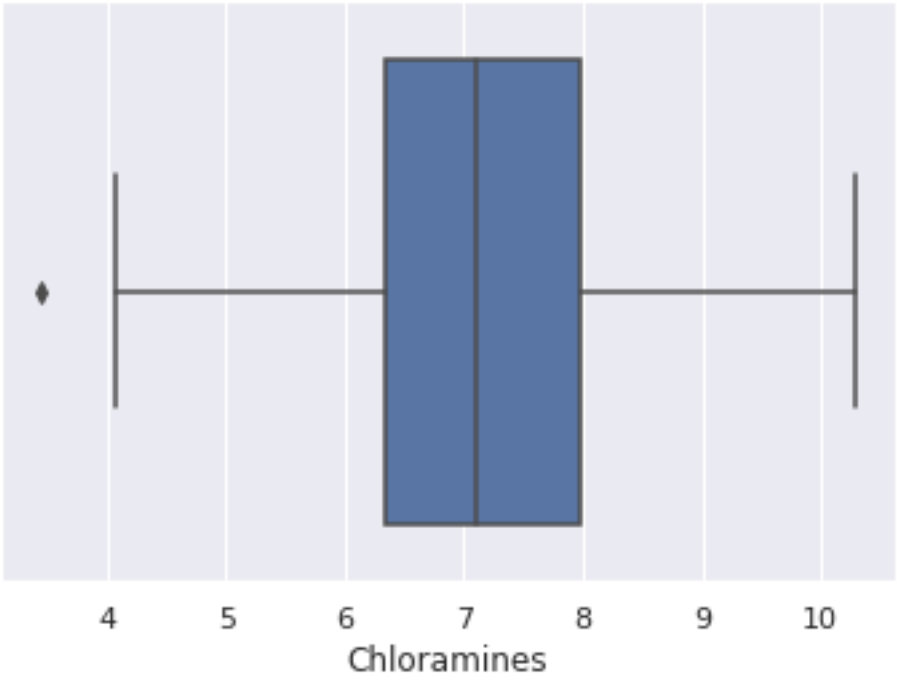

Selanjutnya, akan diuji apakah kedua data Chloramines tersebut memiliki rata-rata yang sama.

Langkah 1 : Penentuan Hipotesis Nol Pada soal ini, ditentukan bahwa hipotesis nol (H_0) adalah rata-rata 100 data Chloramines awal dan 100 data Chloramines akhir adalah sama. Oleh karena itu, diambil

$$H_0 : \mu_{ChloraminesAwal} - \mu_{ChloraminesAkhir} = 0$$

Langkah 2: Penentuan Hipotesis Alternatif Diambil hipotesis alternatif dari permasalahan ini adalah rata-rata 100 data Chloramines awal dan 100 data Chloramines akhir berbeda. Oleh karena itu diambil

$$H_1 : \mu_{ChloraminesAwal} - \mu_{ChloraminesAkhir} \neq 0$$

Langkah 3: Penentuan Nilai Signifikansi dan Daerah kritis Diambil nilai signifikansi (α) bernilai 5%. Akan dihitung nilai daerah kritisnya. Dikarenakan dilakukan proses pengujian pada rata-rata, maka digunakanlah distribusi t.

Sebelumnya, akan dihitung terlebih dahulu nilai derajat kebebasan dari dua buah sampel. Berikut ini adalah rumus untuk menghitung derajat kebebasan.

$$v = n_1 + n_2 - 2$$

Berikut ini adalah perhitungannya menggunakan python

[ ]:
```
v_Chloramines = ChloraminesAwal.count() + ChloraminesAkhir.count() - 2
v_Chloramines
```

[ ]:
```
198
```

Selanjutnya akan dihitung nilai titik kritisnya untuk mencari daerah kritisnya.

[ ]:
```
tValue = scipy.stats.t.ppf(0.05/2, v_Chloramines)
tValue
```

[ ]:
```
-1.972017477833896
```

Oleh karena itu, daerah kritisnya adalah

$$t < -1.972 \vee t > 1.972$$

Langkah 4: Pengujian Statistik Akan dilakukan pengujian statistik. Akan dihitung nilai berikut

$$t_0 = \frac{(\bar{x}_1 - \bar{x}_2) - d_0}{s_p\sqrt{1/n_1 + 1/n_2}}$$

yang dalam hal ini, $\bar{x}_1$ menyatakan rata-rata sampel dari 100 data pertama (ChloraminesAwal) dan $\bar{x}_2$ menyatakan rata-rata dari 100 data akhir (ChloraminesAkhir) dan s_p menyatakan simpangan baku gabungan dari kedua sampel. Nilai s_p dapat dihitung dengan rumus berikut.

$$s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

Berikut ini adalah perhitungan nilai s_p

[ ]:
```
n1 = ChloraminesAwal.count()
n2 = ChloraminesAkhir.count()
s1_sqr = ChloraminesAwal.var(ddof=1)
s2_sqr = ChloraminesAkhir.var(ddof=1)
```

[ ]:
```
sp_sqr = (((n1-1)*s1_sqr)+((n2-1)*s2_sqr))/(n1+n2-2)
sp = np.sqrt(sp_sqr)
sp
```

[ ]:
```
1.396564491851799
```

Selanjutnya akan dihitung nilai t_0

[ ]:
```
x1_bar = np.mean(ChloraminesAwal)
x2_bar = np.mean(ChloraminesAkhir)
```

[ ]:
```
t0 = (x1_bar - x2_bar - 0)/(sp*np.sqrt(1/n1+1/n2))
t0
```

[ ]:
```
-0.7059424842236872
```

Akan dihitung nilai p dari data yang diketahui diatas

[ ]:
```
p = scipy.stats.t.cdf(t0,  v_Chloramines) * 2
p
```

[ ]:
```
0.48105368584331587
```

Langkah 5: Pengambilan Keputusan Dikarenakan $p = 0.481 > 0.05$ dan $t_0 = -0.706 > -1.972$ dan $t_0 = -0.706 < 1.972$, maka hipotesis H_0 diterima. Oleh karena itu, nilai rata-rata 100 data pertama dan 100 data terakhir Chloramines tersebut sama.

1.7.4 Soal 5.d.

Pada soal ini, akan diuji apakah proporsi bagian awal dan bagian akhir kolom sulfate apabila dibagi menjadi 2 sama rata memiliki proporsi nilai bagian awal Turbidity yang lebih dari 4 lebih besar daripada bagian akhir. Sebelum itu kami membagi dataset Turbidity menjadi dua bagian sama besar, yaitu sebagai berikut.

[ ]:
```
TurbidityAwal = data["Turbidity"].iloc[:data["Turbidity"].size//2]
TurbidityAkhir = data["Turbidity"].iloc[data["Turbidity"].size//2:]
TurbidityAwal.info()
TurbidityAkhir.info()
```

```
<class 'pandas.core.series.Series'>
RangeIndex: 1005 entries, 0 to 1004
Series name: Turbidity
Non-Null Count  Dtype
--------------  -----
1005 non-null   float64
dtypes: float64(1)
memory usage: 8.0 KB
<class 'pandas.core.series.Series'>
RangeIndex: 1005 entries, 1005 to 2009
Series name: Turbidity
Non-Null Count  Dtype
--------------  -----
1005 non-null   float64
dtypes: float64(1)
memory usage: 8.0 KB
```

Berikut ini adalah boxplot dari kedua data Sulfate tersebut.

[ ]:
```
sns.boxplot(x = TurbidityAwal)
```

[ ]:
```
<AxesSubplot:xlabel='Turbidity'>
```

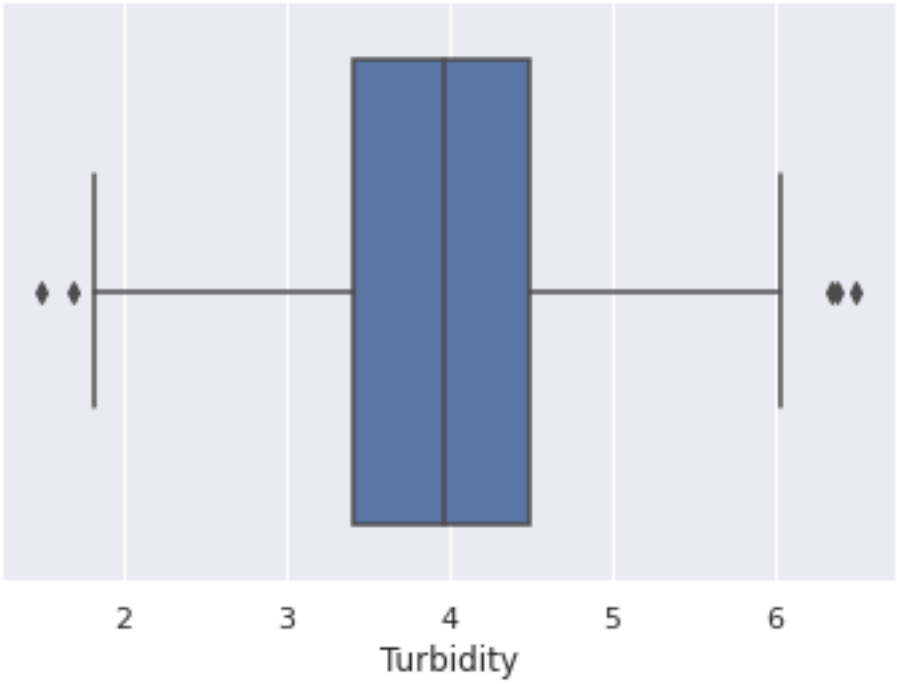

[ ]:
```
sns.boxplot(x = TurbidityAkhir)
```

[ ]:
```
<AxesSubplot:xlabel='Turbidity'>
```

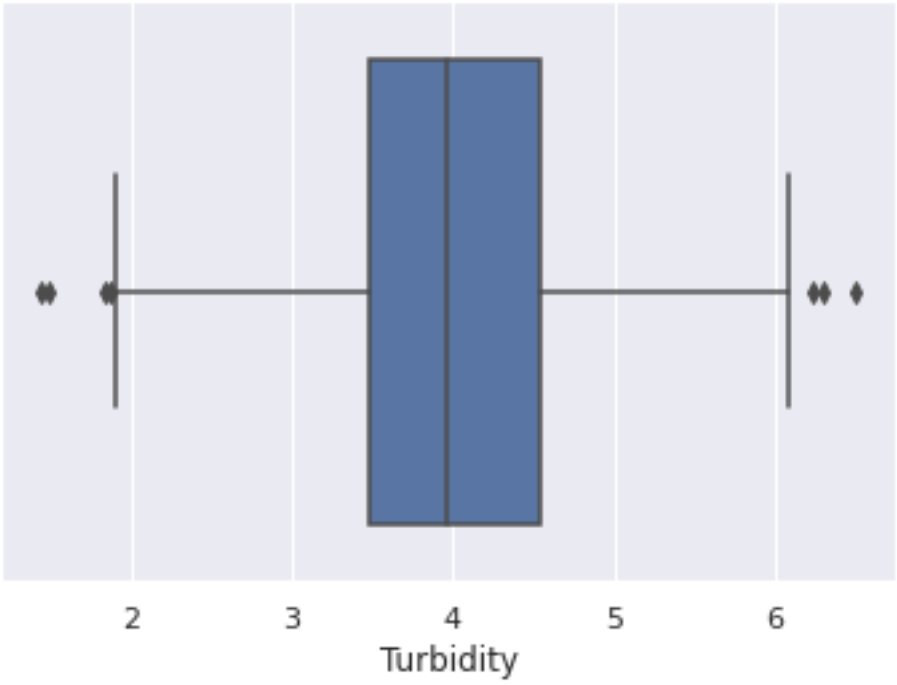

Selanjutnya, akan diuji apakah kedua data Turbidity tersebut memiliki proporsi yang sama

Langkah 1 : Penentuan Hipotesis Nol Pada soal ini, ditentukan bahwa hipotesis nol (H_0) adalah proporsi Turbidity awal yang lebih dari 4 dan Turbidity akhir yang lebih dari 4 adalah sama. Oleh karena itu, diambil

$$H_0 : p_{TurbidityAwal} - p_{TurbidityAkhir} = 0$$

Langkah 2: Penentuan Hipotesis Alternatif Diambil hipotesis alternatif dari permasalahan ini adalah proporsi Turbidity awal yang lebih dari 4 lebih besar dari Turbidity akhir yang lebih dari 4. Oleh karena itu diambil

$$H_1 : p_{TurbidityAwal} - p_{TurbidityAkhir} > 0$$

Langkah 3: Penentuan Nilai Signifikansi dan Daerah kritis Diambil nilai signifikansi (α) bernilai 5%. Akan dihitung nilai daerah kritisnya. Dikarenakan dilakukan proses pengujian pada rata-rata, maka digunakanlah distribusi normal (z).

Selanjutnya akan dihitung nilai titik kritisnya untuk mencari daerah kritisnya.

[ ]:
```
norm = scipy.stats.norm()
z_value = norm.ppf(1-0.05)
z_value
```

[ ]:
```
1.6448536269514722
```

Oleh karena itu, daerah kritisnya adalah

$$z > 1.645$$

Langkah 4: Pengujian Statistik Akan dilakukan pengujian statistik. Akan dihitung nilai berikut

$$z_0 = \frac{\hat{p}_1 - \hat{p}_2}{\sqrt{\hat{p}\hat{q}(1/n_1 + 1/n_2)}}$$

yang dalam hal ini, $\hat{p}_1$ menyatakan proporsi sampel pertama (TurbidityAwal) dan $\hat{p}_2$ menyatakan proporsi dari sampel kedua (TurbidityAkhir) dan $\hat{p}$ menyatakan proporsi gabungan dari kedua sampel, sedangkan $\hat{q}$ menyatakan nilai $1 - \hat{p}$. Nilai $\hat{p}$ dapat dihitung dengan rumus berikut.

$$\hat{p} = \frac{x_1 + x_2}{n_1 + n_2}$$

Berikut ini adalah perhitungan nilai $\hat{p}$

```
[ ]: x1 = TurbidityAwal[TurbidityAwal > 4].count()
     x2 = TurbidityAkhir[TurbidityAkhir > 4].count()
     n1 = TurbidityAwal.count()
     n2 = TurbidityAkhir.count()
```

```
[ ]: hat_p = (x1+x2)/(n1+n2)
     hat_p
```

```
[ ]: 0.48507462686567165
```

Selanjutnya akan dihitung nilai p_1, p_2, dan nilai q.

```
[ ]: p1 = x1/n1
     p2 = x2/n2
     q = 1 - p
```

Selanjutnya akan dihitung nilai z_0

```
[ ]: z0 = (p1 - p2)/(np.sqrt(hat_p*q*(1/n1+1/n2)))
     z0
```

```
[ ]: -0.13336987097338307
```

Akan dihitung nilai p dari data yang diketahui diatas

```
[ ]: p = 1 - norm.cdf(z0)
     p
```

```
[ ]: 0.5530495640039329
```

Langkah 5: Pengambilan Keputusan Dikarenakan $p = 0.553 > 0.05$ dan $z_0 = -0.133 < 1.645$, maka hipotesis H_0 diterima. Oleh karena itu, nilai proporsi keduanya adalah sama.

1.7.5 Soal 5.e.

Pada soal ini, akan diuji apakah variansi bagian awal dan bagian akhir kolom sulfate apabila dibagi menjadi 2 sama rata memiliki rata-rata yang sama. Sebelum itu kami membagi dataset Sulfate menjadi dua bagian sama besar, yaitu sebagai berikut.

```
[ ]: SulfateAwal = data["Sulfate"].iloc[:data["Sulfate"].size//2]
     SulfateAkhir = data["Sulfate"].iloc[data["Sulfate"].size//2:]
     SulfateAwal.info()
     SulfateAkhir.info()
```

```
<class 'pandas.core.series.Series'>
RangeIndex: 1005 entries, 0 to 1004
Series name: Sulfate
Non-Null Count  Dtype
```

```
--------------  -----
1005 non-null   float64
dtypes: float64(1)
memory usage: 8.0 KB
<class 'pandas.core.series.Series'>
RangeIndex: 1005 entries, 1005 to 2009
Series name: Sulfate
Non-Null Count  Dtype
--------------  -----
1005 non-null   float64
dtypes: float64(1)
memory usage: 8.0 KB
```

Berikut ini adalah boxplot dari kedua data Sulfate tersebut.

[ ]:
```
sns.boxplot(x = SulfateAwal)
```

[ ]:
```
<AxesSubplot:xlabel='Sulfate'>
```

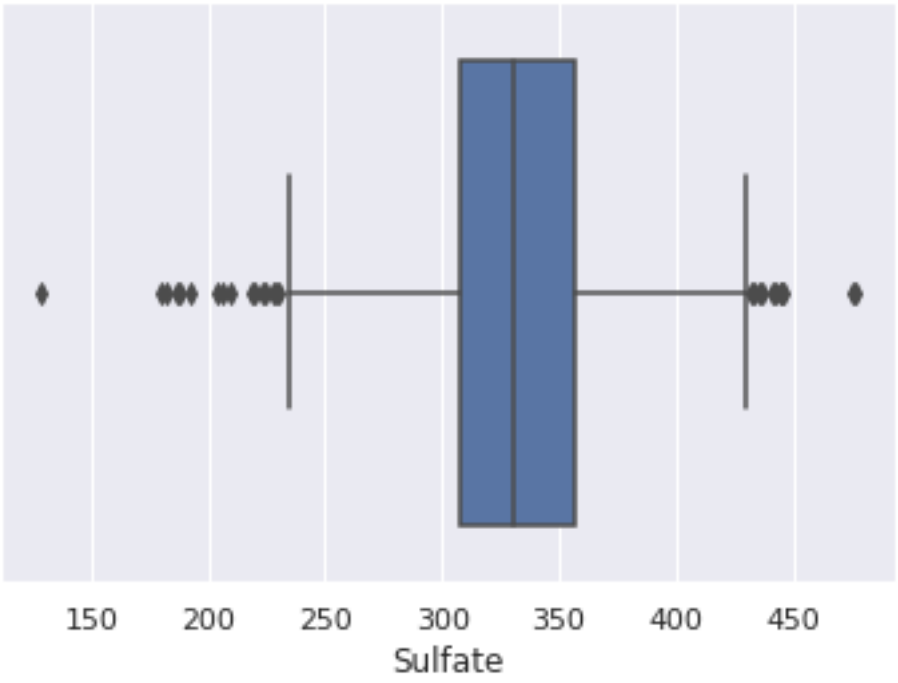

[ ]:
```
sns.boxplot(x = SulfateAkhir)
```

[ ]:
```
<AxesSubplot:xlabel='Sulfate'>
```

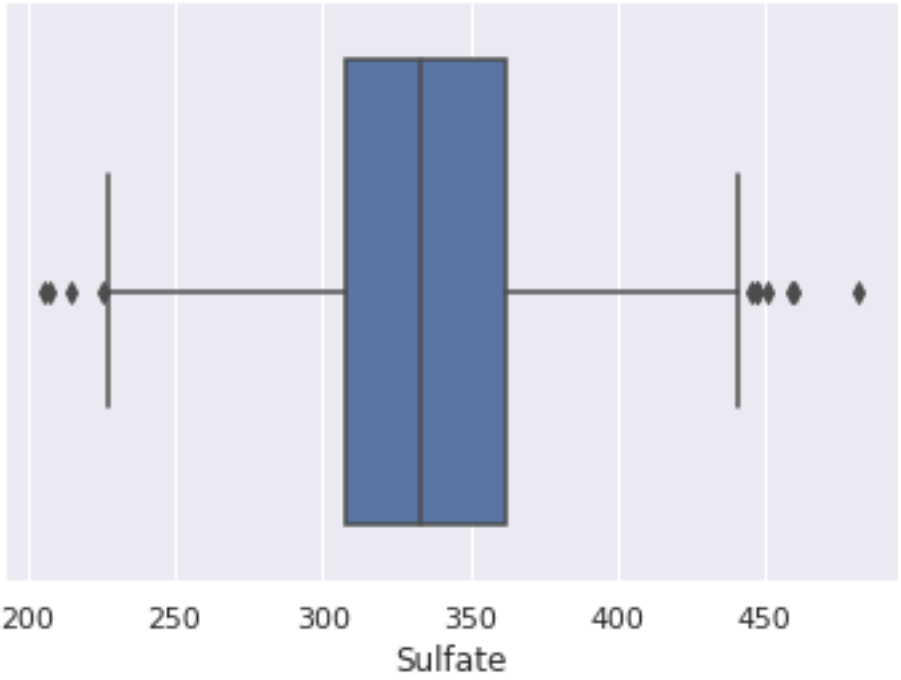

Selanjutnya, akan diuji apakah kedua data Sulfate tersebut memiliki rata-rata yang sama.

Langkah 1 : Penentuan Hipotesis Nol Pada soal ini, ditentukan bahwa hipotesis nol (H_0) adalah variansi Sulfate awal dan Sulfate akhir adalah sama. Oleh karena itu, diambil

$$H_0 : \sigma^2_{SulfateAwal} = \sigma^2_{SulfateAkhir}$$

Langkah 2: Penentuan Hipotesis Alternatif Diambil hipotesis alternatif dari permasalahan ini adalah variansi Sulfate awal dan Sulfate akhir berbeda. Oleh karena itu diambil

$$H_1 : \sigma^2_{SulfateAwal} \neq \sigma^2_{SulfateAkhir}$$

Langkah 3: Penentuan Nilai Signifikansi dan Daerah kritis Diambil nilai signifikansi (α) bernilai 5%. Akan dihitung nilai daerah kritisnya. Dikarenakan dilakukan proses pengujian pada rata-rata, maka digunakanlah distribusi f.

Sebelumnya, akan dihitung terlebih dahulu nilai derajat kebebasan v_1 dan v_2. Berikut ini adalah rumus untuk menghitung derajat kebebasan tersebut.

$$v_1 = n_1 - 1$$
$$v_2 = n_2 - 1$$

Berikut ini adalah perhitungannya menggunakan python

```
[ ]: v1 = SulfateAwal.count() - 1
     v2 = SulfateAkhir.count() - 1
     print(v1)
     print(v2)
```

```
1004
1004
```

Selanjutnya akan dihitung nilai titik kritisnya untuk mencari daerah kritisnya.

```
[ ]: fAwal = scipy.stats.f.ppf(0.05/2, v1, v2)
     fAkhir = scipy.stats.f.ppf(1 - 0.05/2, v1, v2)
     print(f'fAwal = {fAwal}')
     print(f'fAkhir = {fAkhir}')
```

```
fAwal = 0.883572344355818
fAkhir = 1.1317692392568777
```

Oleh karena itu, daerah kritisnya adalah

$$f < 0.884 \vee f > 1.132$$

Langkah 4: Pengujian Statistik Akan dilakukan pengujian statistik. Akan dihitung nilai berikut

$$f_0 = \frac{s_1^2}{s_2^2}$$

yang dalam hal ini, s_1^2 menyatakan variansi sampel dari dataset pertama (SulfateAwal) dan s_2^2 menyatakan variansi dari dataset kedua (SulfateAkhir).

Berikut ini adalah perhitungan nilai f_0

```
[ ]: s1_sqr = SulfateAwal.var(ddof=1)
     s2_sqr = SulfateAkhir.var(ddof=1)
```

```
[ ]: f0 = s1_sqr/s2_sqr
     f0
```

```
[ ]: 1.0152511043950063
```

Langkah 5: Pengambilan Keputusan Dikarenakan $f_0 = 1.015 > 0.884$ dan $f_0 = 1.015 < 1.132$ maka hipotesis f_0 berada di luar titik kritis, sehingga hipotesis H_0 diterima.

Jadi, kesimpulannya adalah variansi dari kedua data tersebut adalah sama.

1.8 Nomor 6: Korelasi

Dua buah dataset dapat memiliki satu sama lain. Nilai koefisien korelasi dua dataset tersebut menyatakan bagaimana dua buah data saling berkorelasi satu sama lain. Rumus yang menyatakan korelasi dari data adalah sebagai berikut.

$$\rho_{xy} = \frac{n\sum x_i y_i - \sum x_i \sum y_i}{\sqrt{\sum x_i^2 - (\sum x_i)^2} \cdot \sqrt{\sum y_i^2 - (\sum y_i)^2}} = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$

Nilai ρ_{xy} menentukan korelasi antara dua buah data. Berikut ini adalah cara memaknai nilai koefisien korelasi tersebut.

- Semakin nilai ρ_{xy} mendekati 0, kedua kolom tidak berkorelasi.
- Semakin nilai ρ_{xy} mendekati 1, kedua kolom berbanding lurus.
- Semakin nilai ρ_{xy} mendekati -1, kedua kolom berbanding terbalik.

1.8.1 Korelasi Data pH dan Potability

Berikut ini adalah scatter plot dari data pH dengan Potability.

[ ]:
```
sns.scatterplot(x = "pH", y = "Potability", data = data)
```

[ ]:
```
<AxesSubplot:xlabel='pH', ylabel='Potability'>
```

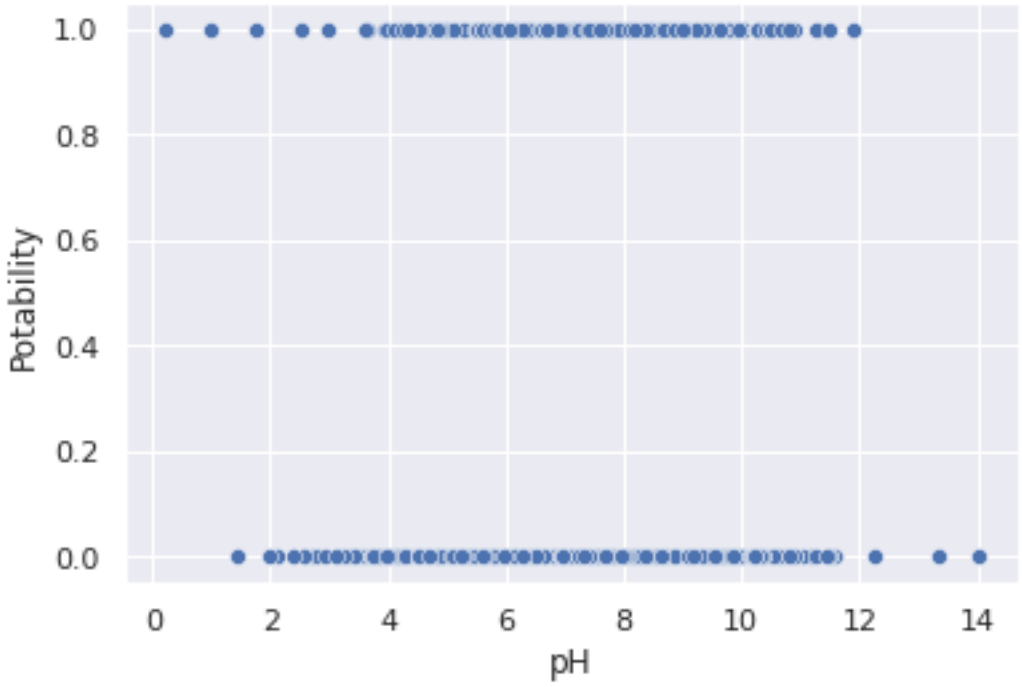

Selanjutnya akan dihitung nilai koefisien korelasi antarkeduanya menggunakan python.

[ ]:
```
data["pH"].corr(data["Potability"])
```

[ ]:
```
0.015475094408433492
```

Nilai koefisien korelasi pH dan potability mendekati nol. Oleh karena itu, kedua atribut tersebut tidak memiliki korelasi.

1.8.2 Korelasi Data Hardness dan Potability

Berikut ini adalah scatter plot dari data Hardness dengan Potability.

[ ]:
```
sns.scatterplot(x = "Hardness", y = "Potability", data = data)
```

[ ]:
```
<AxesSubplot:xlabel='Hardness', ylabel='Potability'>
```

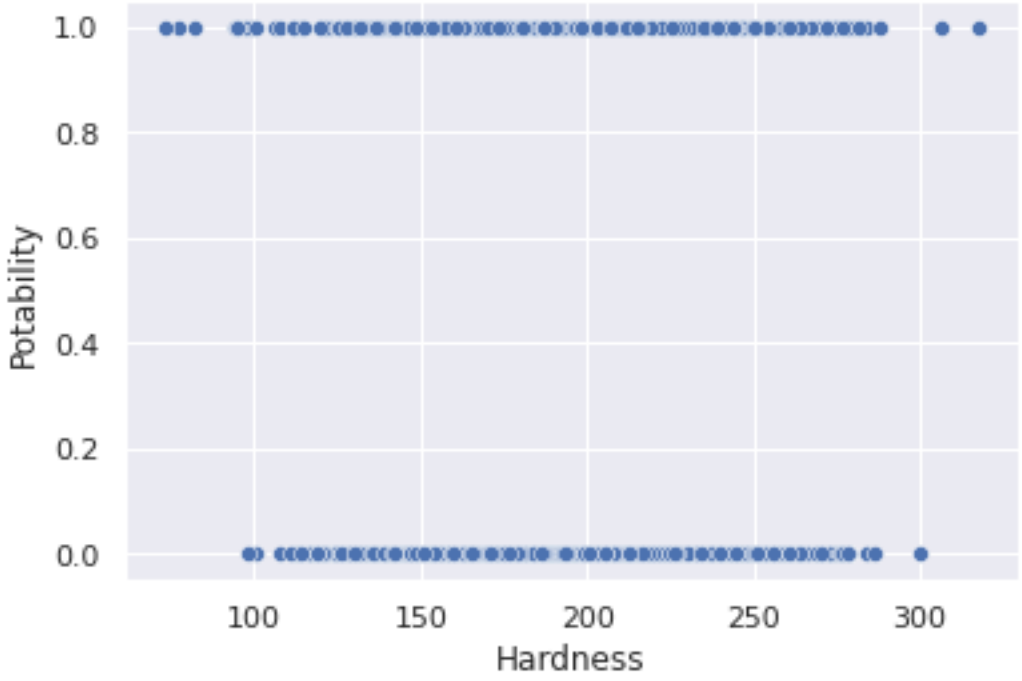

Selanjutnya akan dihitung nilai koefisien korelasi antarkeduanya menggunakan python.

[ ]:
```
data["Hardness"].corr(data["Potability"])
```

[ ]:
```
-0.0014631528959479442
```

Nilai koefisien korelasi Hardness dan potability mendekati nol. Oleh karena itu, kedua atribut tersebut tidak memiliki korelasi.

1.8.3 Korelasi Data Solids dan Potability

Berikut ini adalah scatter plot dari data Solids dengan Potability.

[ ]:
```
sns.scatterplot(x = "Solids", y = "Potability", data = data)
```

[ ]:
```
<AxesSubplot:xlabel='Solids', ylabel='Potability'>
```

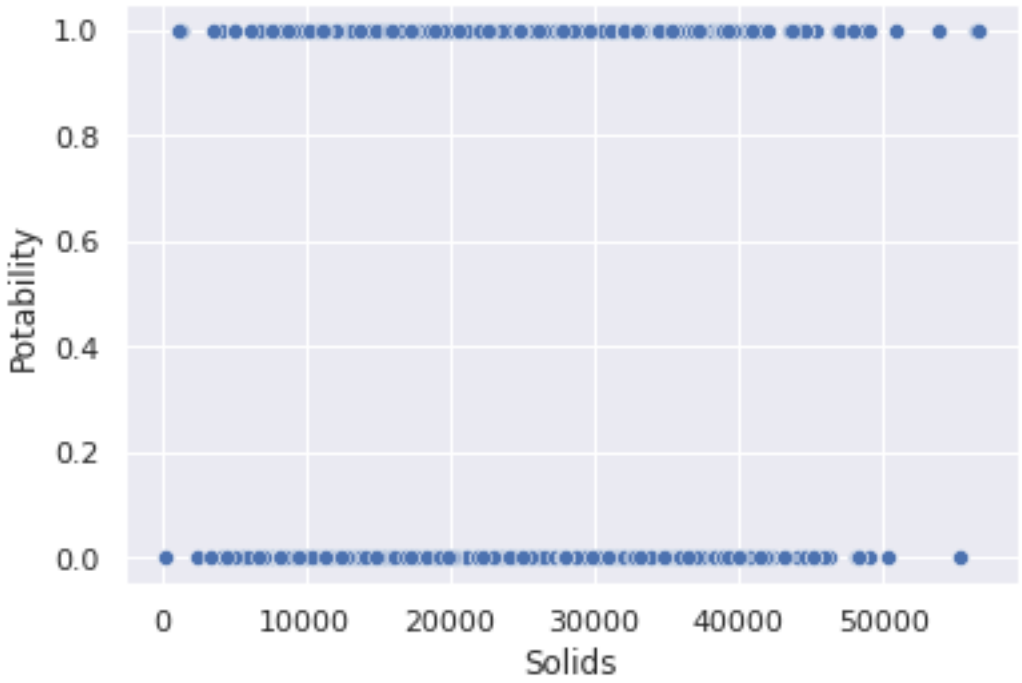

Selanjutnya akan dihitung nilai koefisien korelasi antarkeduanya menggunakan python.

```
[ ]: data["Solids"].corr(data["Potability"])
```

```
[ ]: 0.0389765781817347
```

Nilai koefisien korelasi Solids dan potability mendekati nol. Oleh karena itu, kedua atribut tersebut tidak memiliki korelasi.

1.8.4 Korelasi Data Chloramines dan Potability

Berikut ini adalah scatter plot dari data Chloramines dengan Potability.

```
[ ]: sns.scatterplot(x = "Chloramines", y = "Potability", data = data)
```

```
[ ]: <AxesSubplot:xlabel='Chloramines', ylabel='Potability'>
```

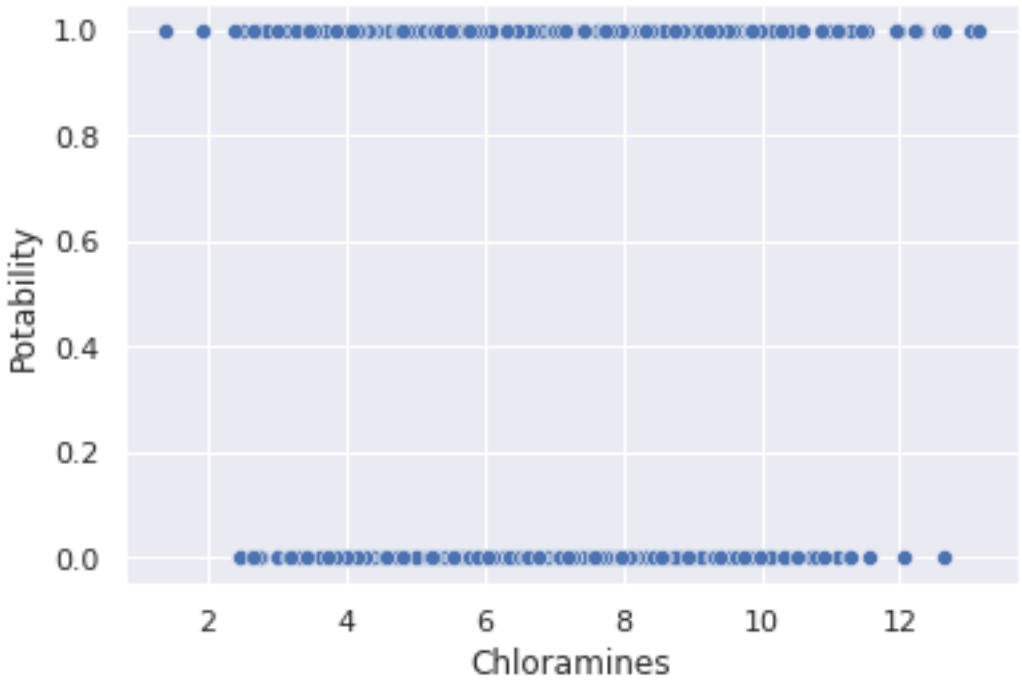

Selanjutnya akan dihitung nilai koefisien korelasi antarkeduanya menggunakan python.

[ ]:
```
data["Chloramines"].corr(data["Potability"])
```

[ ]:
```
0.020778921840524087
```

Nilai koefisien korelasi Chloramines dan potability mendekati nol. Oleh karena itu, kedua atribut tersebut tidak memiliki korelasi.

1.8.5 Korelasi Data Sulfate dan Potability

Berikut ini adalah scatter plot dari data Sulfate dengan Potability.

[ ]:
```
sns.scatterplot(x = "Sulfate", y = "Potability", data = data)
```

[ ]:
```
<AxesSubplot:xlabel='Sulfate', ylabel='Potability'>
```

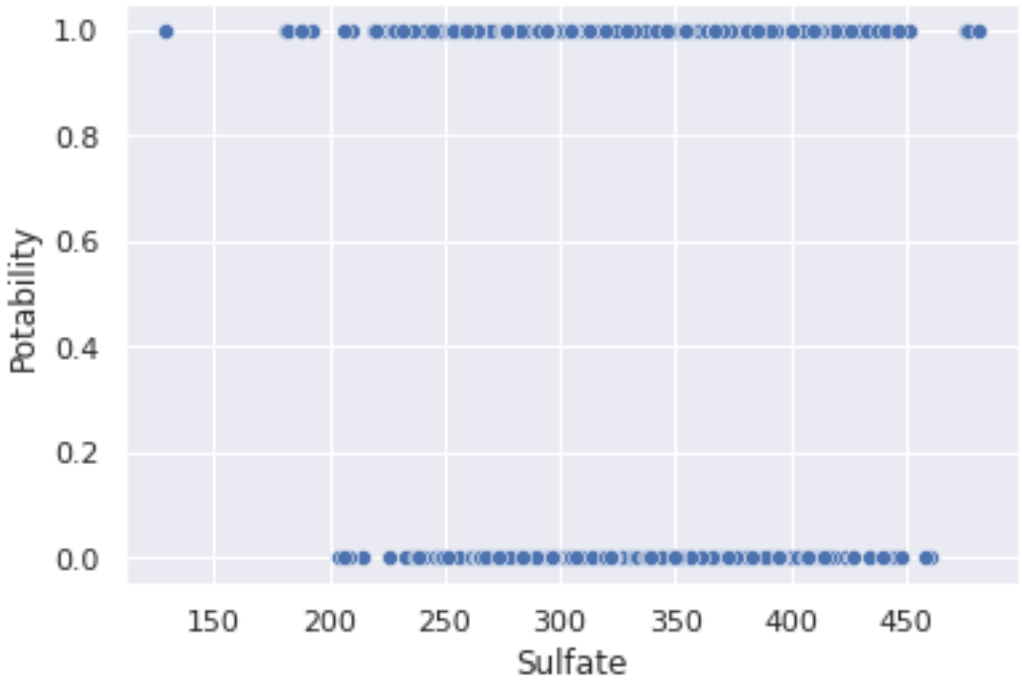

Selanjutnya akan dihitung nilai koefisien korelasi antarkeduanya menggunakan python.

[ ]:
```
data["Sulfate"].corr(data["Potability"])
```

[ ]:
```
-0.01570316441927379
```

Nilai koefisien korelasi Sulfate dan potability mendekati nol. Oleh karena itu, kedua atribut tersebut tidak memiliki korelasi.

1.8.6 Korelasi Data Conductivity dan Potability

Berikut ini adalah scatter plot dari data Conductivity dengan Potability.

[ ]:
```
sns.scatterplot(x = "Conductivity", y = "Potability", data = data)
```

[ ]:
```
<AxesSubplot:xlabel='Conductivity', ylabel='Potability'>
```

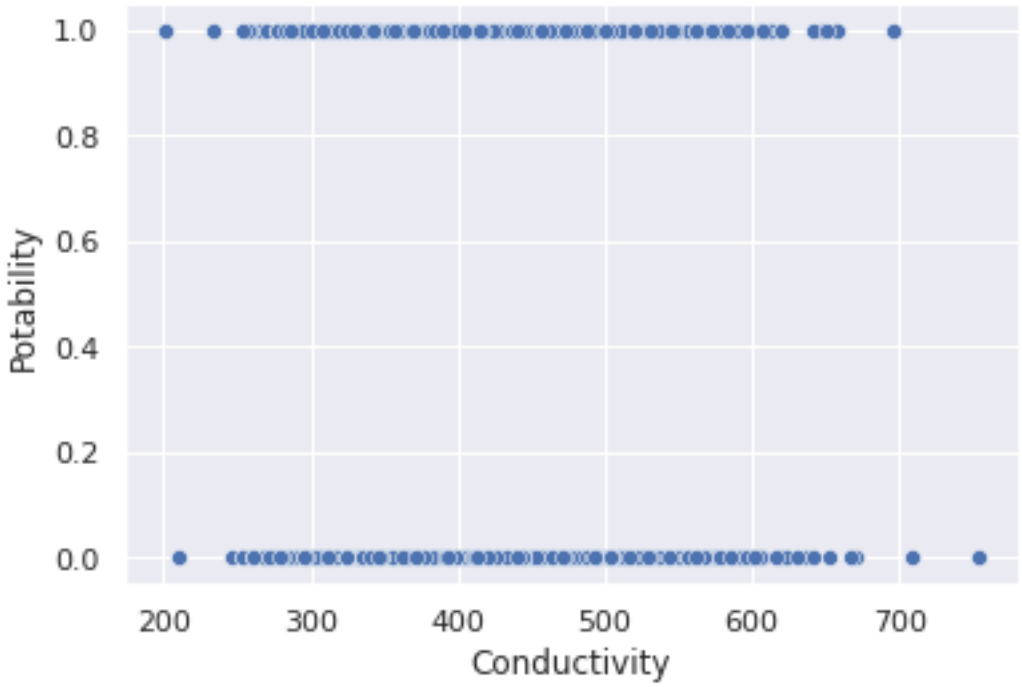

Selanjutnya akan dihitung nilai koefisien korelasi antarkeduanya menggunakan python.

[ ]:
```
data["Conductivity"].corr(data["Potability"])
```

[ ]:
```
-0.016257120111377105
```

Nilai koefisien korelasi Conductivity dan potability mendekati nol. Oleh karena itu, kedua atribut tersebut tidak memiliki korelasi.

1.8.7 Korelasi Data OrganicCarbon dan Potability

Berikut ini adalah scatter plot dari data OrganicCarbon dengan Potability.

[ ]:
```
sns.scatterplot(x = "OrganicCarbon", y = "Potability", data = data)
```

[ ]:
```
<AxesSubplot:xlabel='OrganicCarbon', ylabel='Potability'>
```

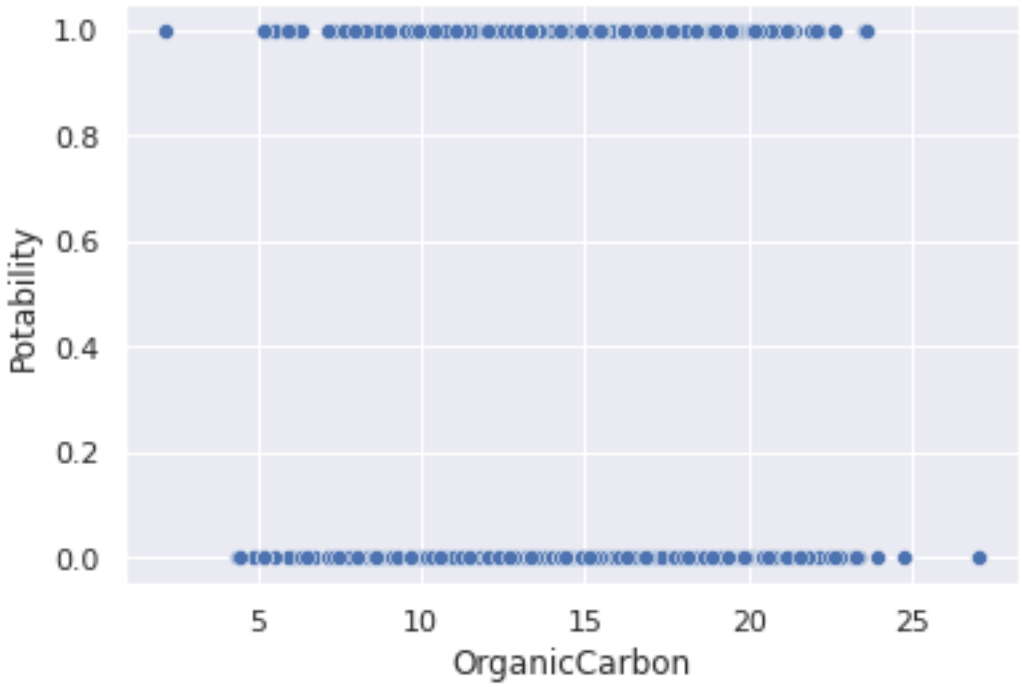

Selanjutnya akan dihitung nilai koefisien korelasi antarkeduanya menggunakan python.

```
[ ]: data["OrganicCarbon"].corr(data["Potability"])
```

```
[ ]: -0.015488461910747282
```

Nilai koefisien korelasi OrganicCarbon dan potability mendekati nol. Oleh karena itu, kedua atribut tersebut tidak memiliki korelasi.

1.8.8 Korelasi Data Trihalomethanes dan Potability

Berikut ini adalah scatter plot dari data Trihalomethanes dengan Potability.

```
[ ]: sns.scatterplot(x = "Trihalomethanes", y = "Potability", data = data)
```

```
[ ]: <AxesSubplot:xlabel='Trihalomethanes', ylabel='Potability'>
```

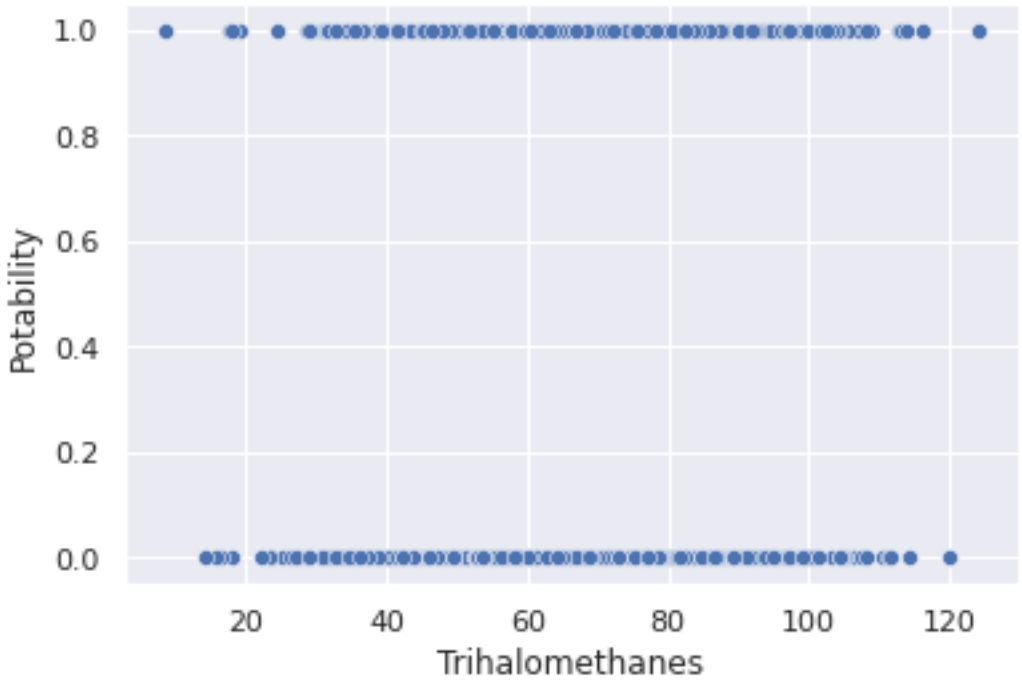

Selanjutnya akan dihitung nilai koefisien korelasi antarkeduanya menggunakan python.

```
[ ]: data["Trihalomethanes"].corr(data["Potability"])
```

```
[ ]: 0.009236711064713004
```

Nilai koefisien korelasi Trihalomethanes dan potability mendekati nol. Oleh karena itu, kedua atribut tersebut tidak memiliki korelasi.

1.8.9 Korelasi Data Turbidity dan Potability

Berikut ini adalah scatter plot dari data Turbidity dengan Potability.

```
[ ]: sns.scatterplot(x = "Turbidity", y = "Potability", data = data)
```

```
[ ]: <AxesSubplot:xlabel='Turbidity', ylabel='Potability'>
```

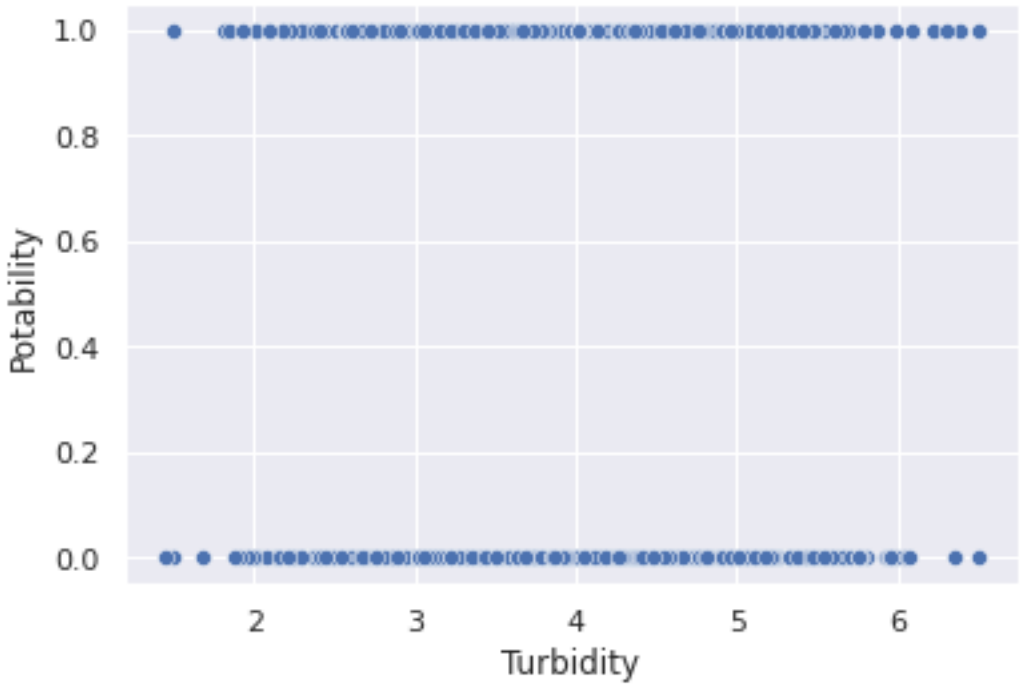

Selanjutnya akan dihitung nilai koefisien korelasi antarkeduanya menggunakan python.

```
[ ]: data["Turbidity"].corr(data["Potability"])
```

```
[ ]: 0.022331042640622675
```

Nilai koefisien korelasi Turbidity dan potability mendekati nol. Oleh karena itu, kedua atribut tersebut tidak memiliki korelasi.